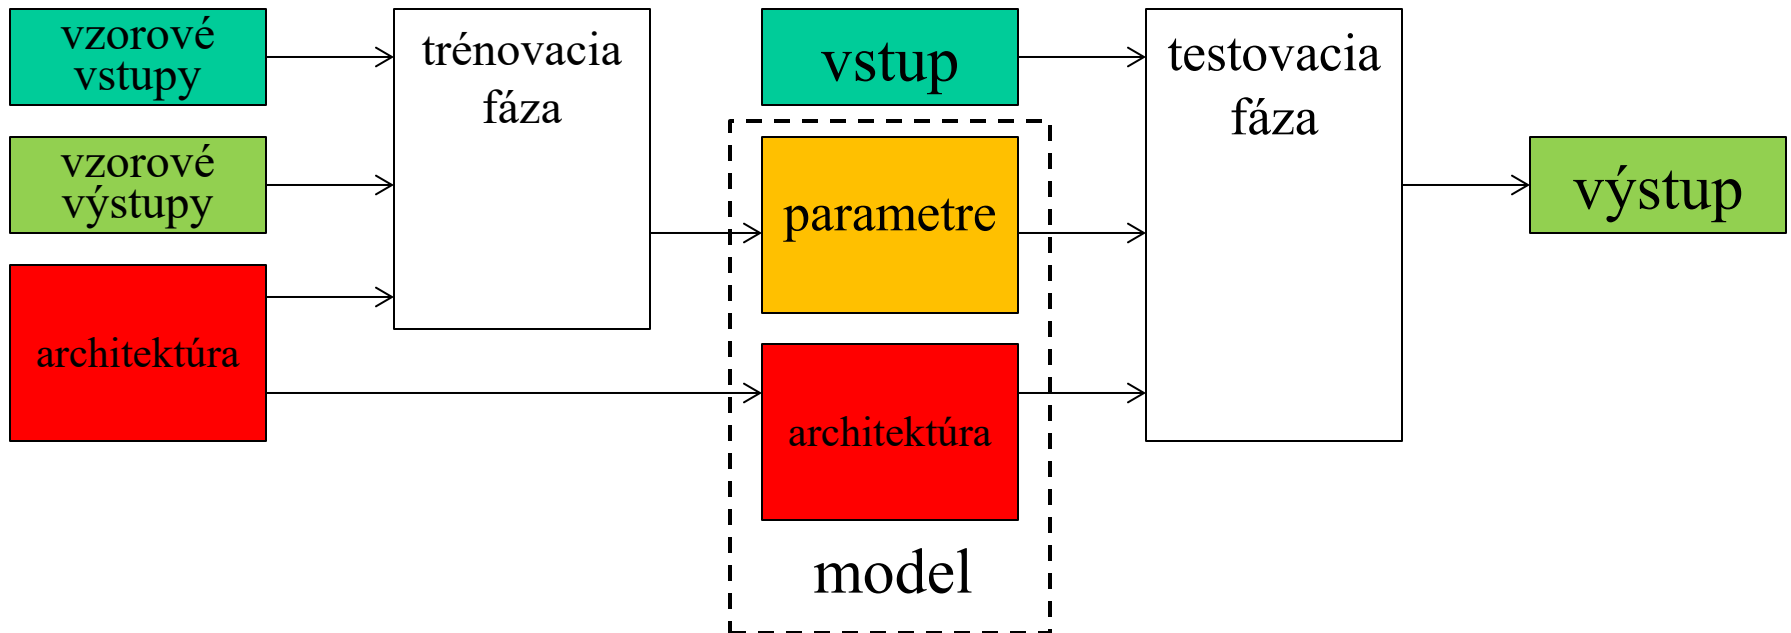



Strojové učenie

- Hlboké učenie je špeciálny druh strojového učenia
- Strojové učenie je empirický prístup k programovaniu
- Zo vzorových vstupov a výstupov skonštruujeme model
- Pomocou modelu transformujeme ďalšie vstupy



Dataset

Datasey majú stovky až desaťtisíce príkladov vstupu a želaného výstupu. Napr. dataset MNIST má 60000 vzoriek 28 x 28 x 1:




Univerzálny stroj



*vzorový
vstup*

Predstavme si, že máme stroj, o ktorom vieme, že pri správnom nastavení kolečiek, realizuje našu úlohu, to správne nastavenie však nepoznáme...



vzorový výstup

parametre



Univerzálny stroj




*vzorový
vstup*

Niečo nastavíme, ale nedá nám
to taký výstup aký chceme

vzorový výstup



parametre



výstup

Univerzálny stroj





*vzorový
vstup*

Určíte by sme privítali, keby sme
z porovnania vzorového výstupu
a výstupu
vedeli ako

vzorový výstup

potočiť kolečkami, aby sa
správanie stroja zlepšilo



výstup


parametre

Neurónová sieť





*vzorový
vstup*

Presne túto vlastnosť má
neurónová sieť



parametre


vzorový výstup



výstup

Trénovanie

Loss Curve




Preučenie




vstup

Dúfame potom, že toto nastavenie bude fungovať aj pre vstupy, ktoré nemáme v datasete. Fungovať to nemusí. Najlepšie nastavenie nemusí byť to, ktoré dáva najmenšiu chybu na vzorkách




parametre



výstup

Loss Curve

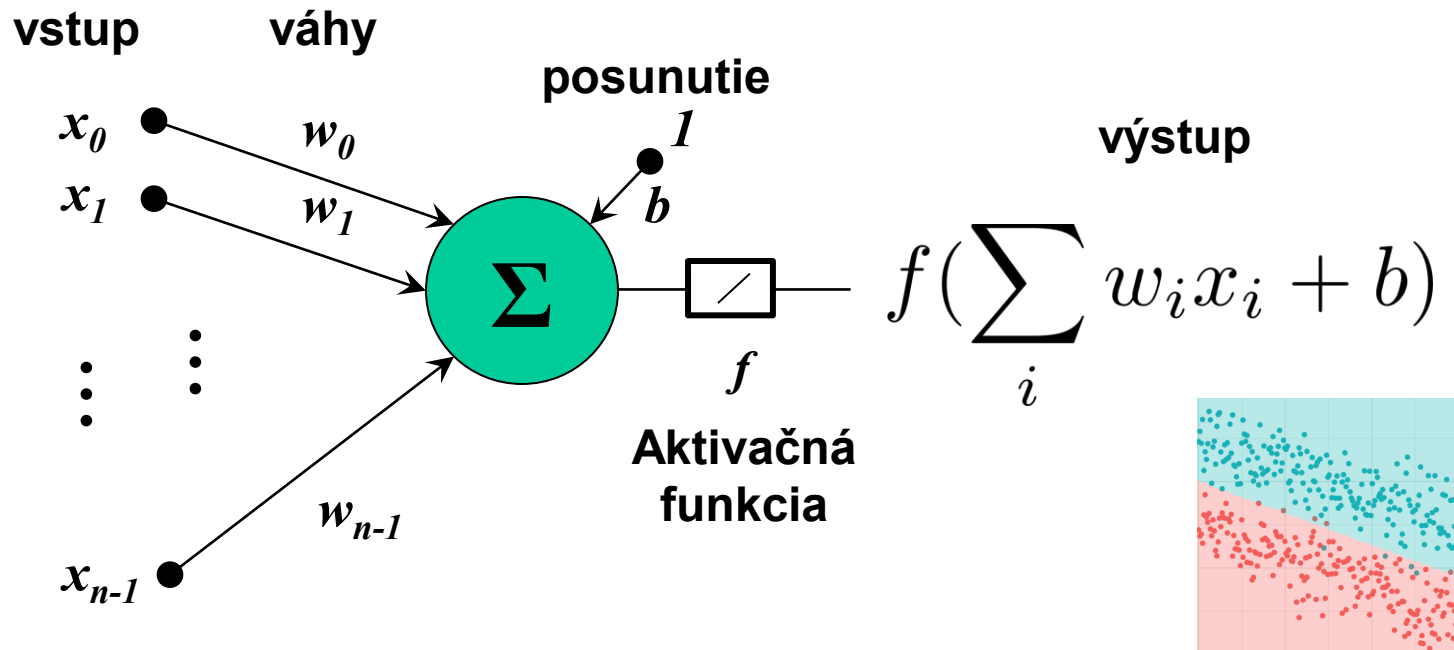


Preto rozdeľujeme dataset na trénovaciu a testovaciu časť, čo nám umožňuje vidieť či alebo kedy sa neurónová sieť preučila

Ako vyzerá taká neurónová sieť zvnútra?

- Hoci silnou motiváciou pri vymyslení vhodnej architektúry neurónovej siete bola snaha napodobniť ľudský mozog, podobá sa naň pramálo
- Kvôli tejto motivácii však nazývame základné stavebné prvky neurónmi
- Neuróny sú organizované do vrstiev
- Vrstvy sú organizované do blokov
- Každý blok spracúva jeden tenzor na druhý
- Tenzor je viacrozmerné pole dát, napríklad našich 10 obrázkov predstavuje vstupný tenzor s rozmermi
10 x 3 x 416 x 416 (dávka, počet kanálov, $\underbrace{\text{výška, šírka}}_{\text{počet pixelov}})$


Neurón




- Neurón počíta skalárny súčin vstupu s váhami, pripočíta posunutie a aplikuje aktivačnú funkciu
- Aktivačná funkcia môže byť: lineárna, sigmoida, hyperbolický tangens, ...

Úvod: Aktivačné funkcie


Lineárna




ReLU




Leaky
ReLU




sigmoida



exp



softmax



Linear regression

