Backbone

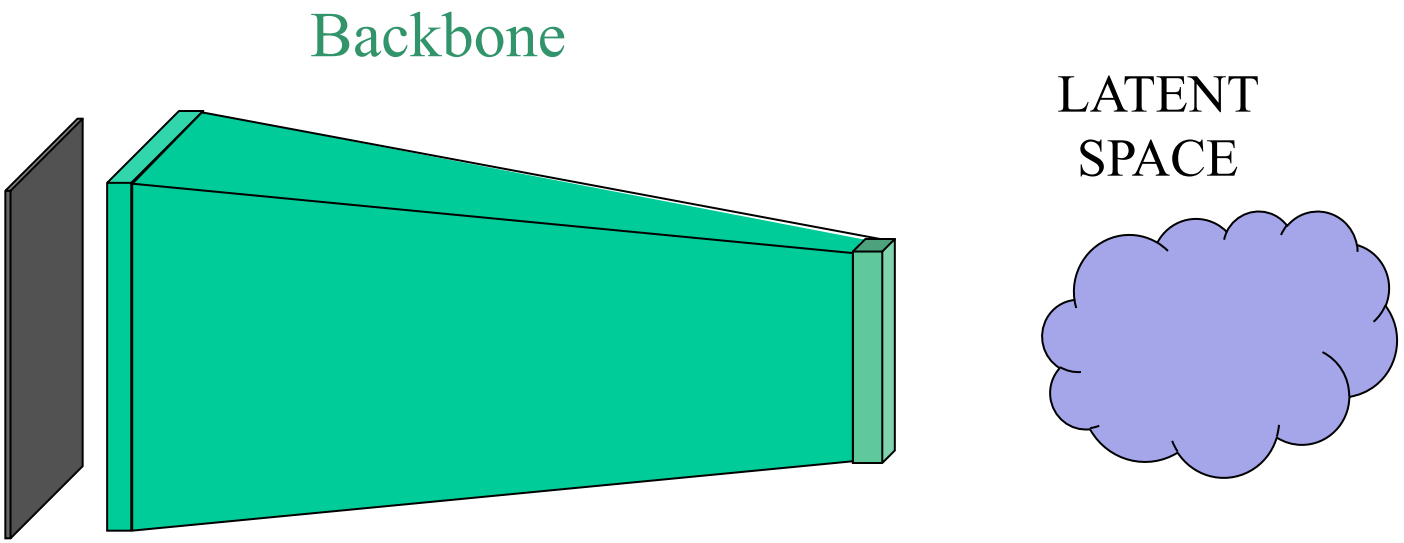

- Časť siete, ktorá obraz premení na príznaky

Backbones

- AlexNet
- VGG (VGG16, VGG19)
- ResNet (ResNet50, ResNet18)
- DarkNet
- Inception (Inception v3)
- Xception
- MobileNet

AlexNet

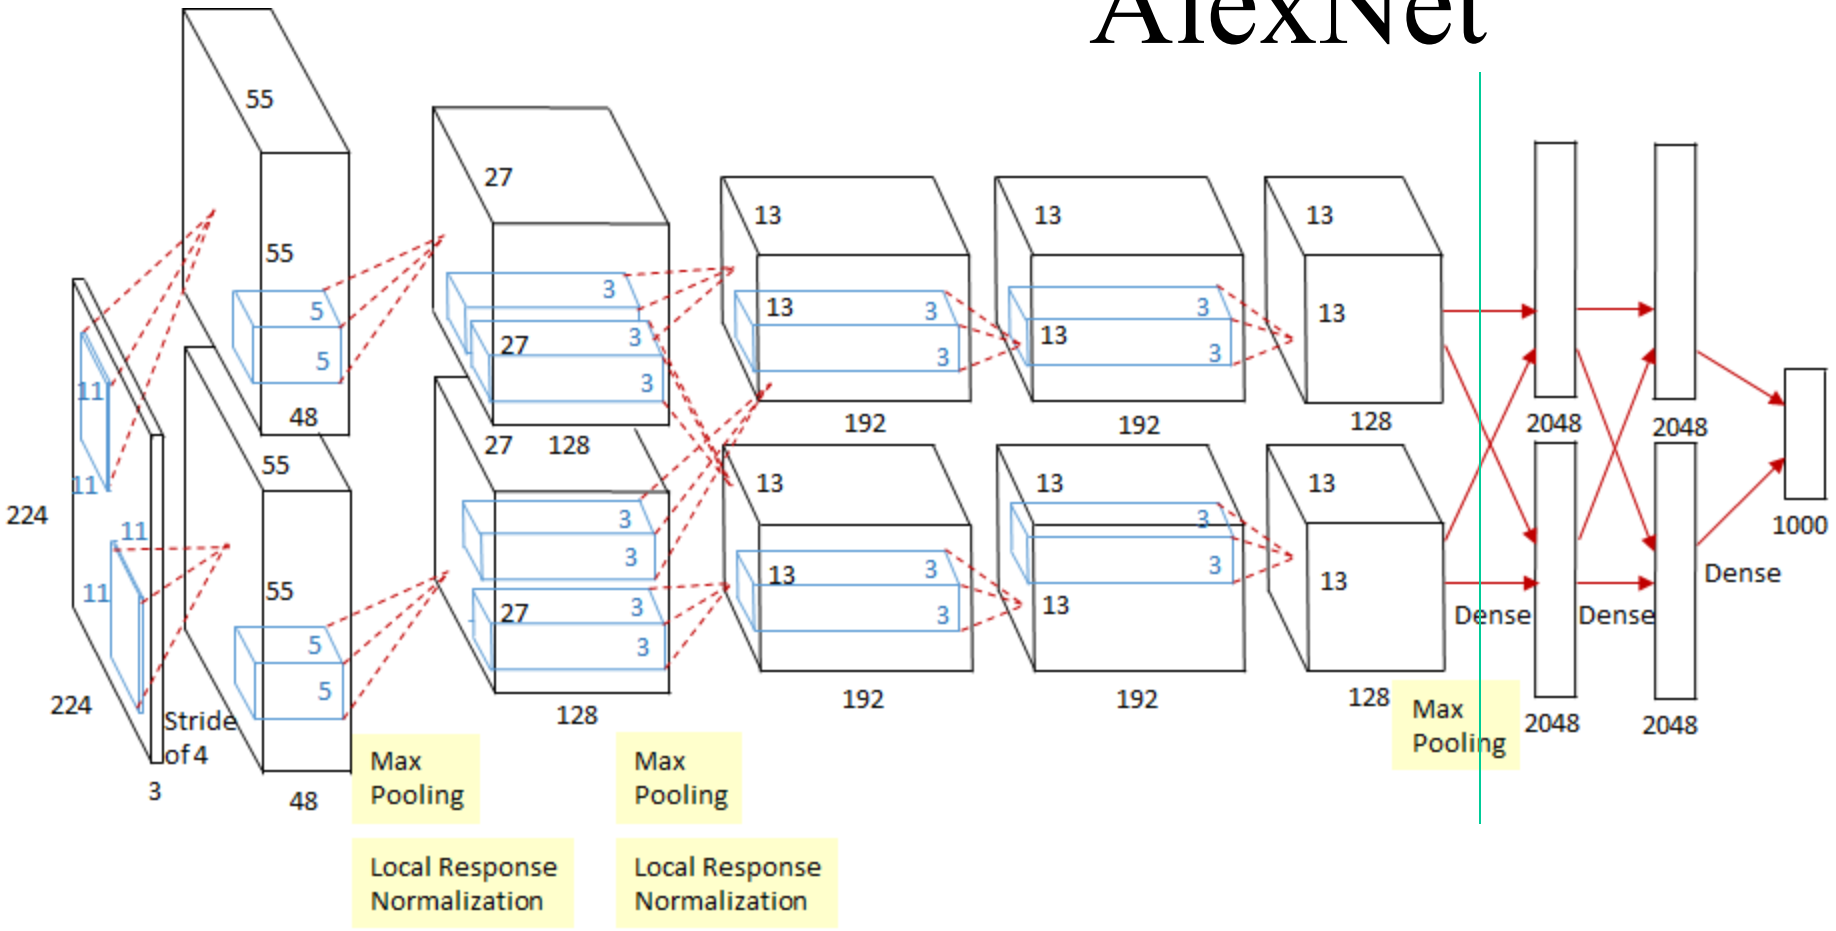
55
55
48
55
55
48
224
224
11
11
11
11
Stride of 4
3
27
27
128
27
27
128
3
5
13
13
192
192
128
2048
2048
1000
Dense
Dense
Dense
2048
2048
Max Pooling
Max Pooling
Local Response Normalization
Local Response Normalization

VGG

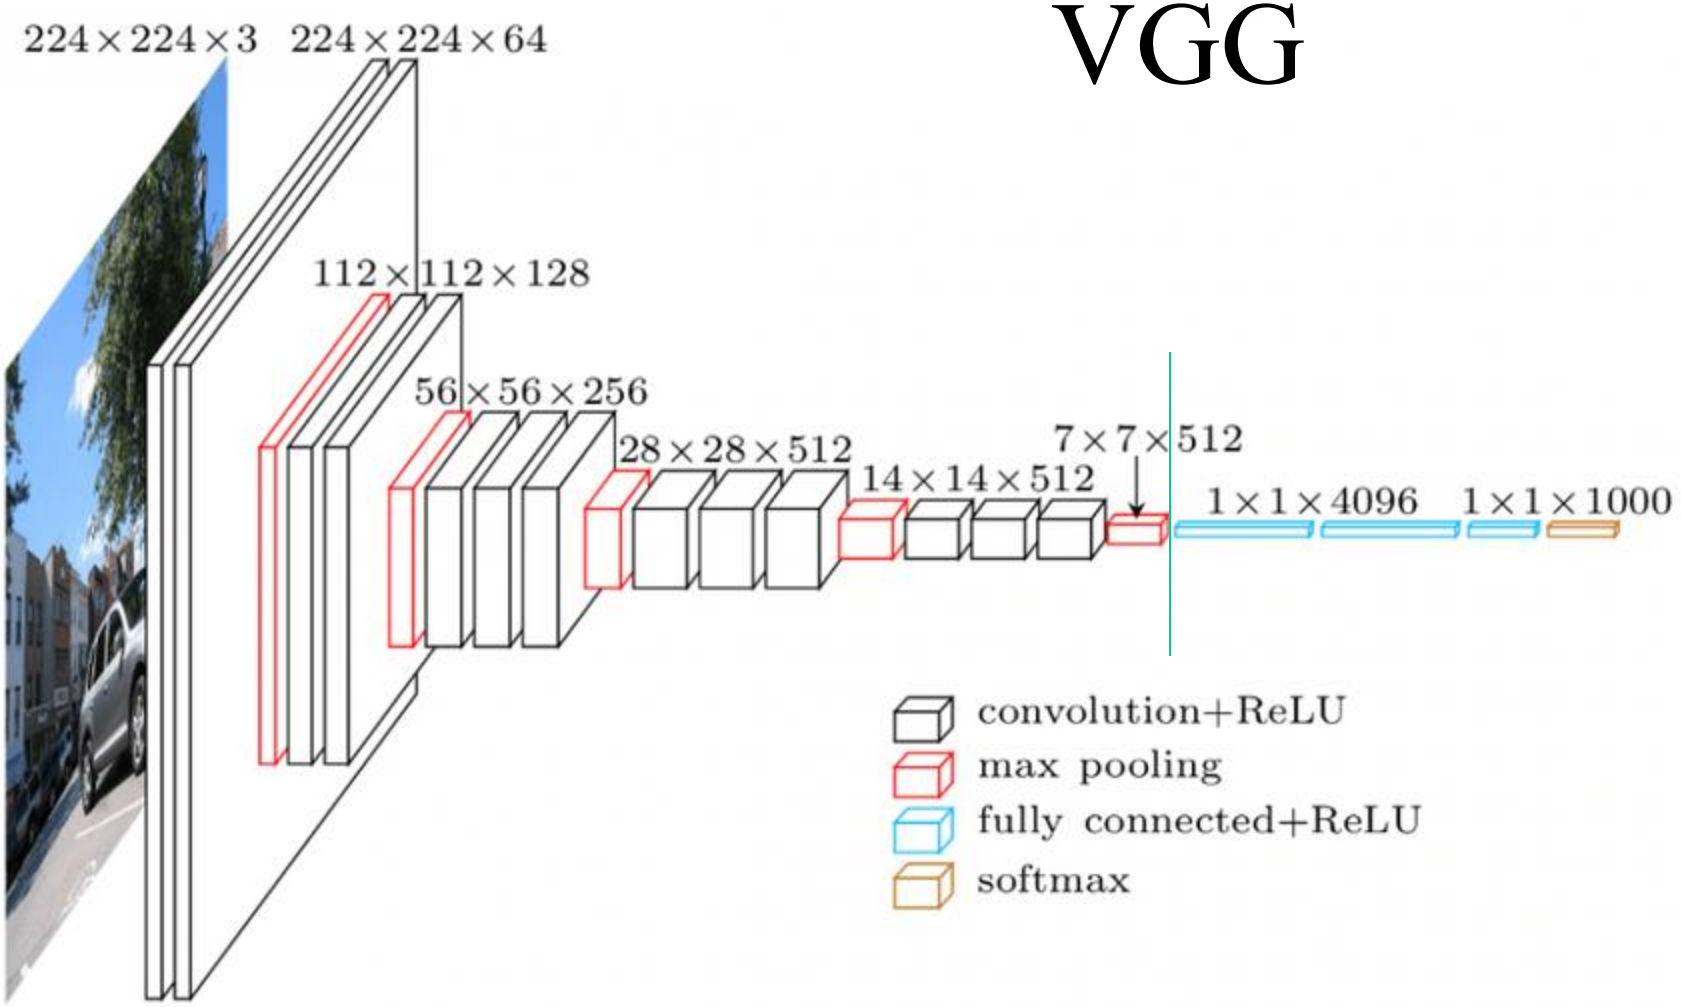
224 × 224 × 3
224 × 224 × 64
112 × 112 × 128
56 × 56 × 256
28 × 28 × 512
14 × 14 × 512
7 × 7 × 512
1 × 1 × 4096
1 × 1 × 1000
convolution+ReLU
max pooling
fully connected+ReLU
softmax

ResNet

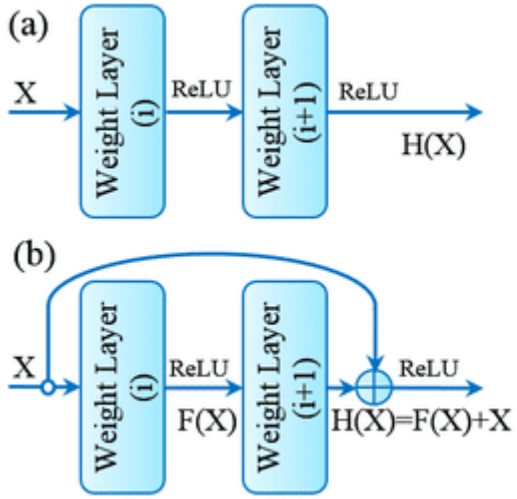
(a)
X
Weight Layer (i)
ReLU
Weight Layer (i+1)
ReLU
H(X)
(b)
X
Weight Layer (i)
ReLU
F(X)
Weight Layer (i+1)
ReLU
H(X)=F(X)+X

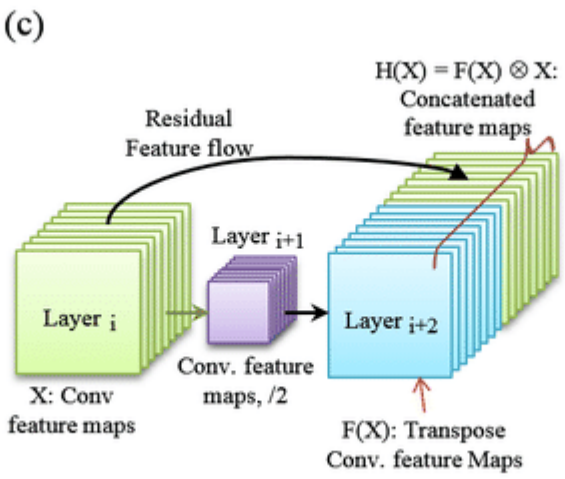
(c)
H(X) = F(X) ⊗ X:
Concatenated feature maps
Residual Feature flow
Layer i+1
Layer i
Layer i+2
X: Conv feature maps
Conv. feature maps, /2
F(X): Transpose Conv. feature Maps

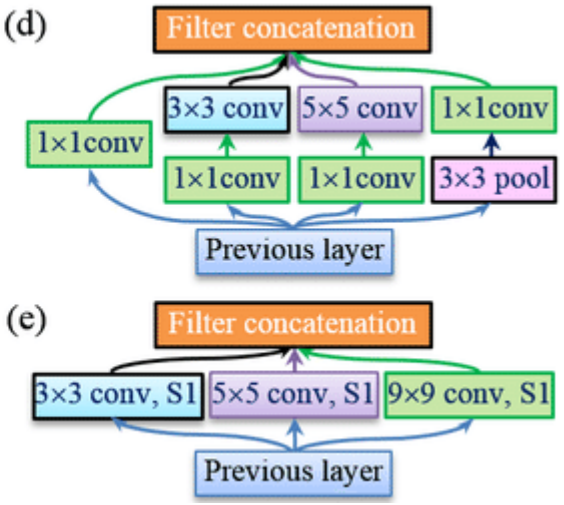
(d)
Filter concatenation
3×3 conv
5×5 conv
1×1conv
1×1conv
1×1conv
1×1conv
3×3 pool
Previous layer
(e)
Filter concatenation
3×3 conv, S1
5×5 conv, S1
9×9 conv, S1
Previous layer

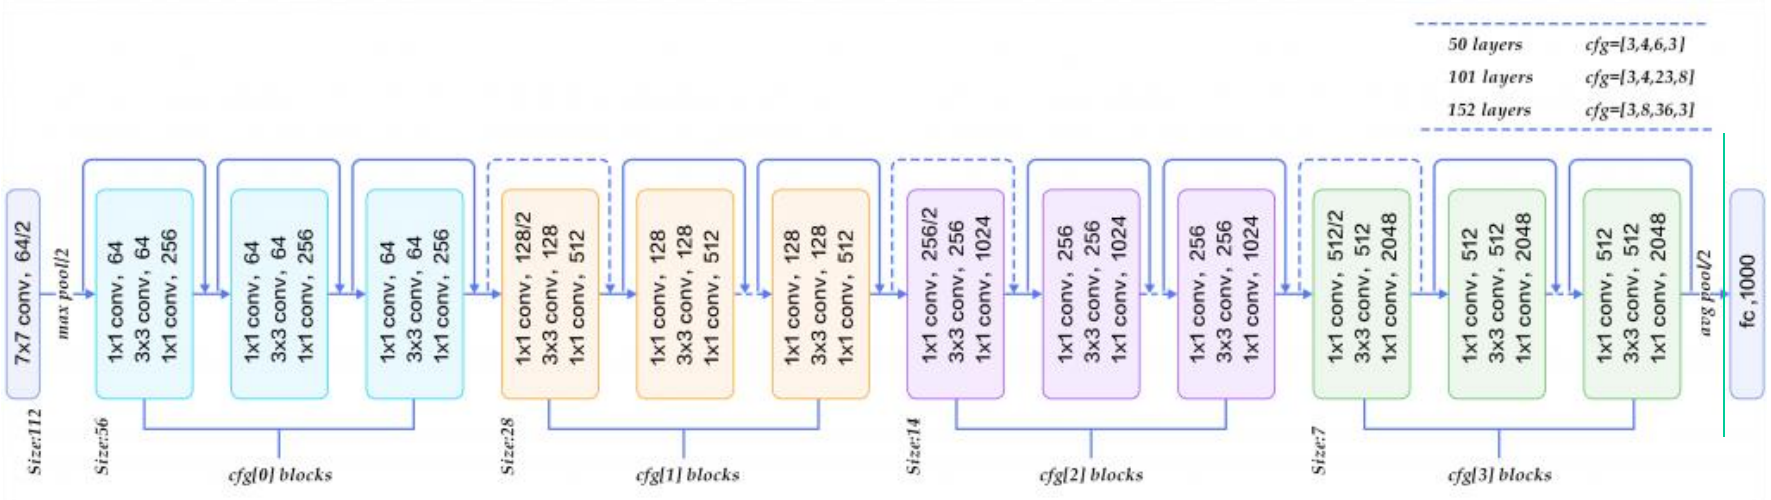
50 layers cfg=[3,4,6,3]
101 layers cfg=[3,4,23,8]
152 layers cfg=[3,8,36,3]
7x7 conv, 64/2
max pool/2
1x1 conv, 64
3x3 conv, 64
1x1 conv, 256
1x1 conv, 128/2
3x3 conv, 128
1x1 conv, 512
1x1 conv, 256/2
3x3 conv, 256
1x1 conv, 1024
1x1 conv, 512/2
3x3 conv, 512
1x1 conv, 2048
avg pool/2
fc ,1000
Size:112
Size:56
Size:28
Size:14
Size:7
cfg[0] blocks
cfg[1] blocks
cfg[2] blocks
cfg[3] blocks

Inception V1

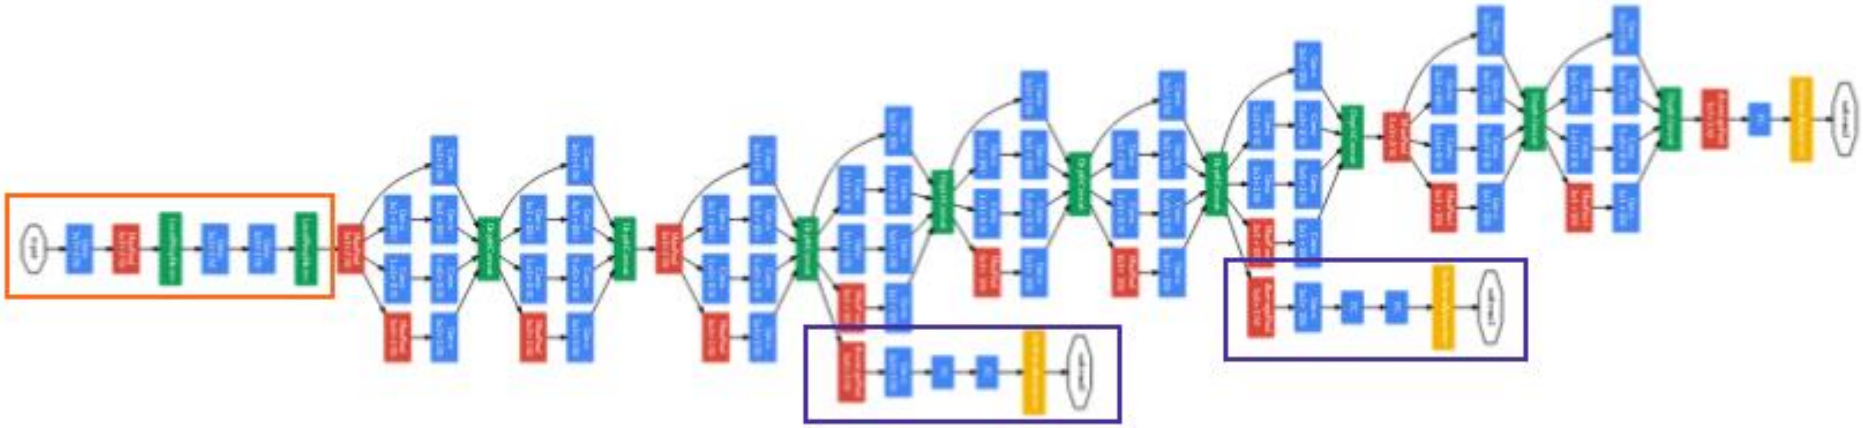

U-Net

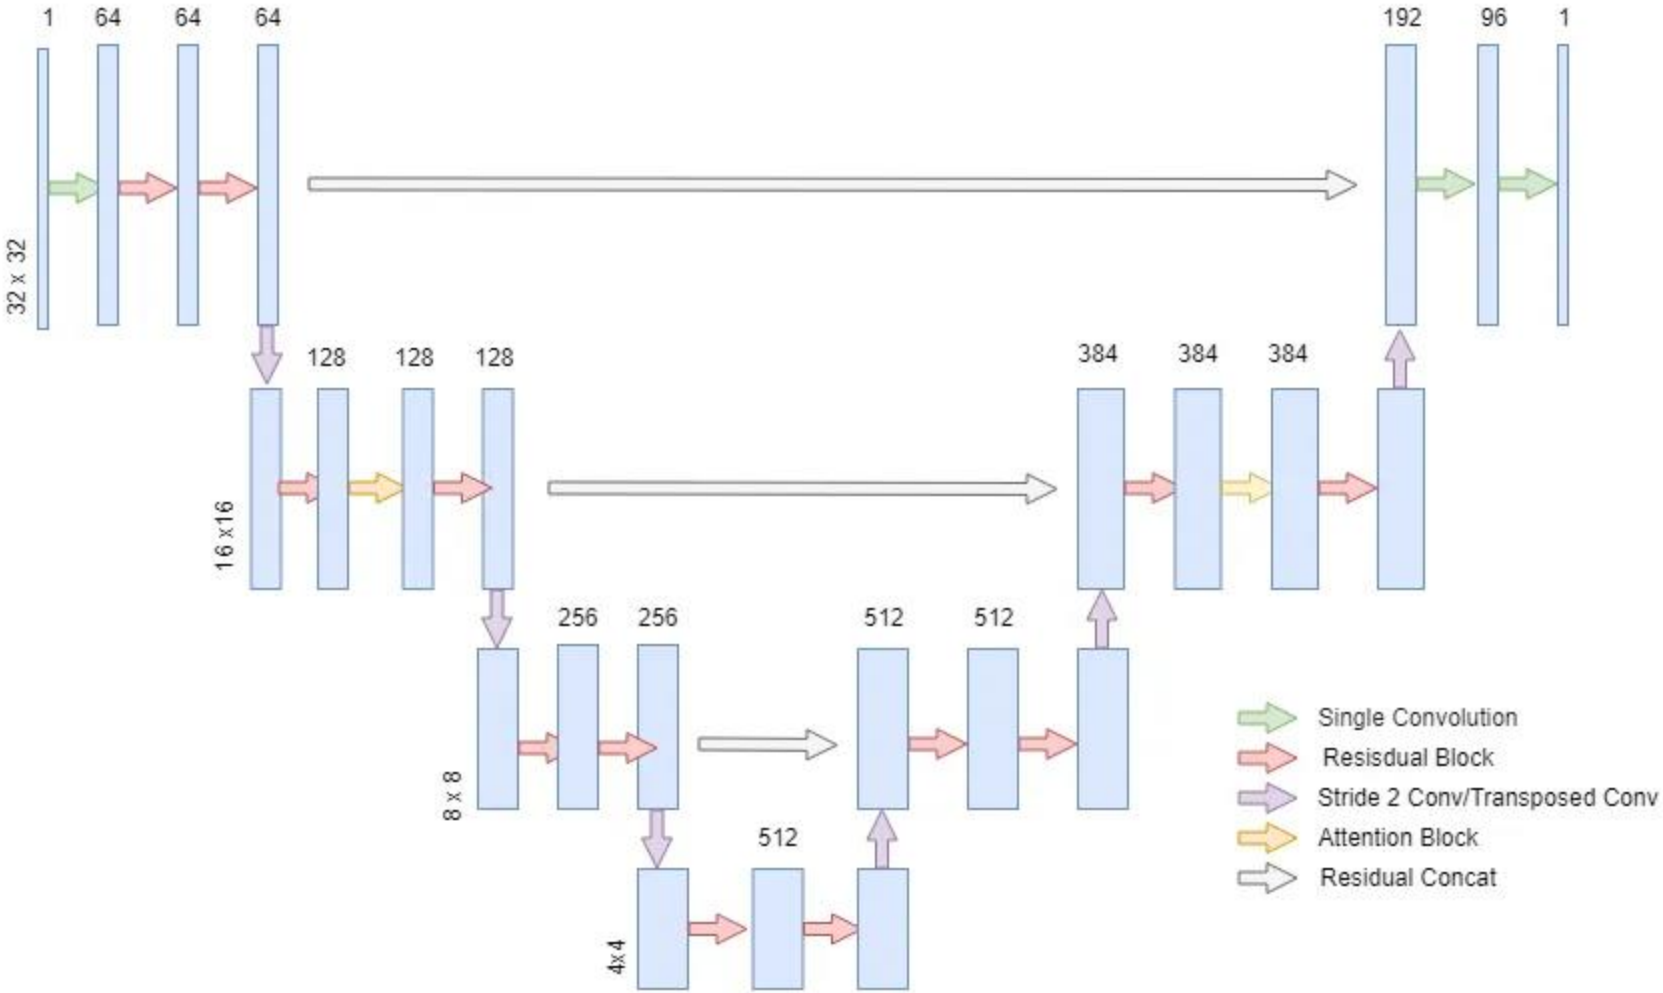
1
64
64
64
192
96
1
32 x 32
128
128
128
384
384
384
16 x16
256
256
512
512
8 x 8
512
4x4
Single Convolution
Resisdual Block
Stride 2 Conv/Transposed Conv
Attention Block
Residual Concat

Predtrénovaný model

- Každá backbone má aj svoje Zoo – zbierku modelov natrénovaných na rôznych datasetoch, napr. na COCO, PascalVOC ...
- Trénovanie siete z predtrénovaného modelu, za ktorý zaradíme svoje (custom) výstupné vrstvy, sa nazýva **transfer learning**

Transfer learning

- Je pravdepodobné, že model na klasifikáciu auta bude v značnej miere podobný modelu pre bicykel

- Preto pri tvorbe druhého môžeme radšej začať od druhého, než na zelenej lúke (from scratch)

- Z modelu natrénovaného pre určitý dataset, napríklad COCO alebo VOC necháme len backbone a ten budeme distribuovať ako **predtrénovaný model**

Fine tuning

- K predtrénovanému modelu pripojíme napr perceptron a trénujeme už len váhy perceptrónu, aby sme získali napr. custom classifier

- Takéto trénovanie je aj oveľa rýchlejšie. Opiera sa však len o hotové features

- Má zmysel preto skúsiť pokračovať v trénovaní, pričom už dovolíme meniť aj váhy backbone. Táto fáza trénovania sa nazýva Fine tuning (jemné doladenie)

Trénovanie hlbokej siete

- Trénovanie hlbokej siete je problematické
- Čím hlbšia je sieť, tým viac hrozí, že sa gradient pri spätnom šírení stratí a váhy v úvodných vrstvách sa vôbec nebudú meniť (vanishing gradient problem)
- Práve riešenie tohto problému predstavuje hlavné rozdiely medzi backbonami (okrem počtu vrstiev, počtu parametrov, rozmeru vstupu a podobne)

Riešenia

- Dropout
- Batch normalization
- Reziduály

Dropout

$$drop(x) = \begin{cases} 0 & \text{ak } rnd < p \\ x\frac{1}{1-p} & \text{inak} \end{cases}$$

ak p = 0.2 20% vynulujeme

80% zosilníme

- Tento problém a jeho riešenia dobre vidno na trénovaní identity
- Na rozdiel od autoencodera však neredukujeme dimenziu, nemáme latentný priesto

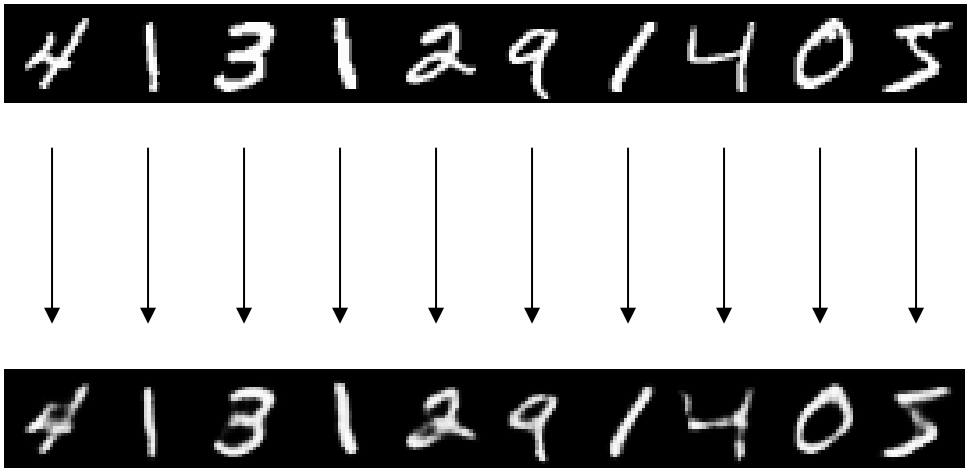

Dataset MNIST

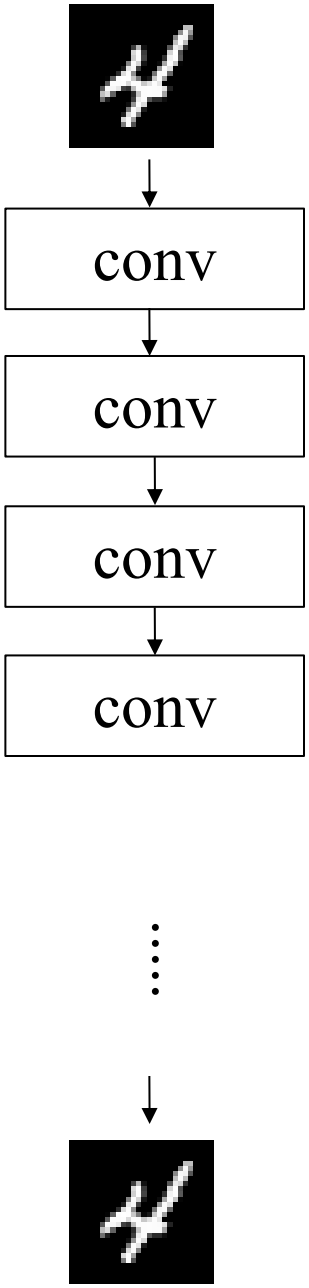

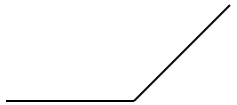

všade: ReLU

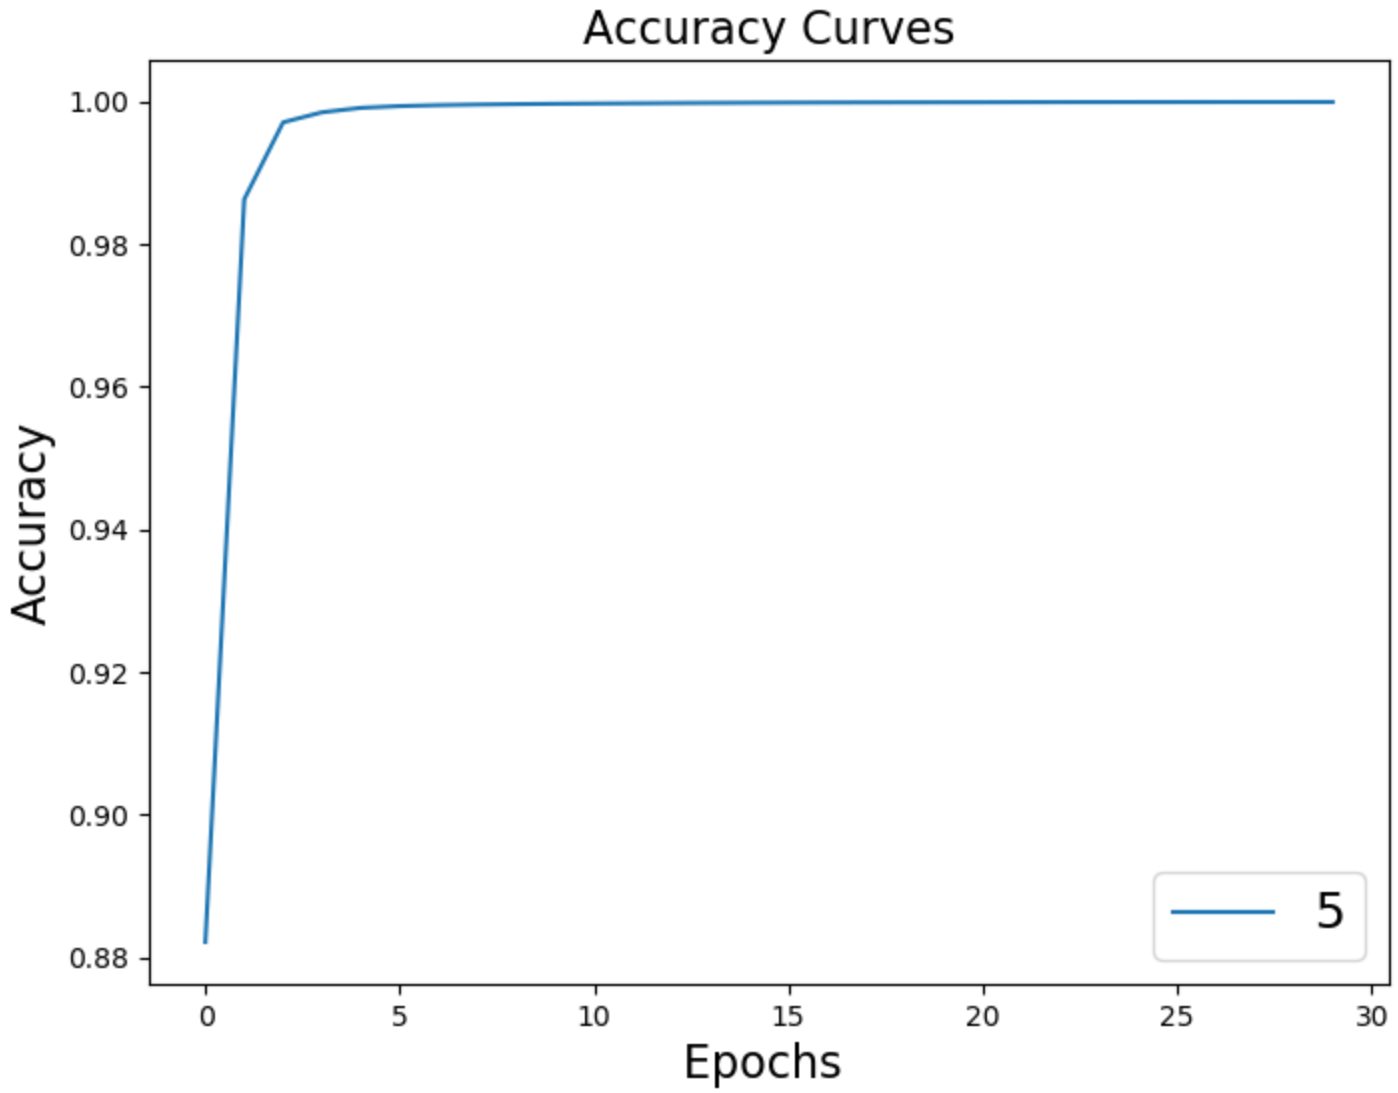
Accuracy Curves
1.00
0.98
0.96
0.94
0.92
0.90
0.88
Accuracy
0
5
10
15
20
25
30
Epochs
5

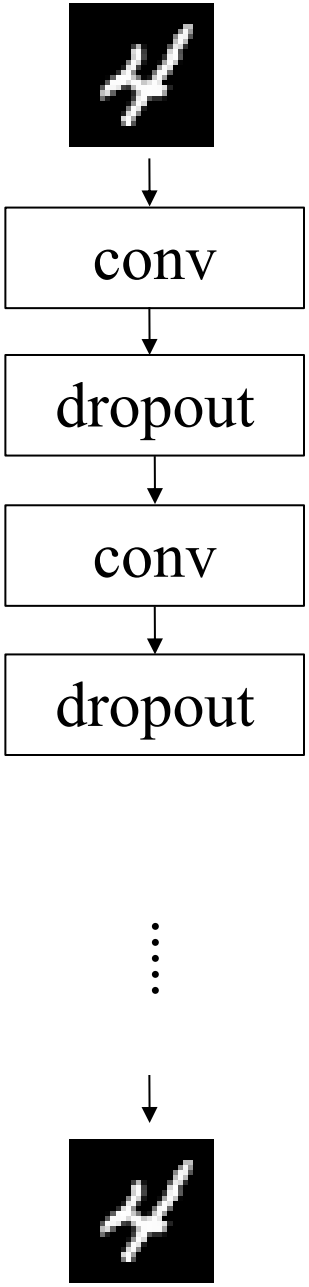
conv
dropout
conv
dropout

- Dropout

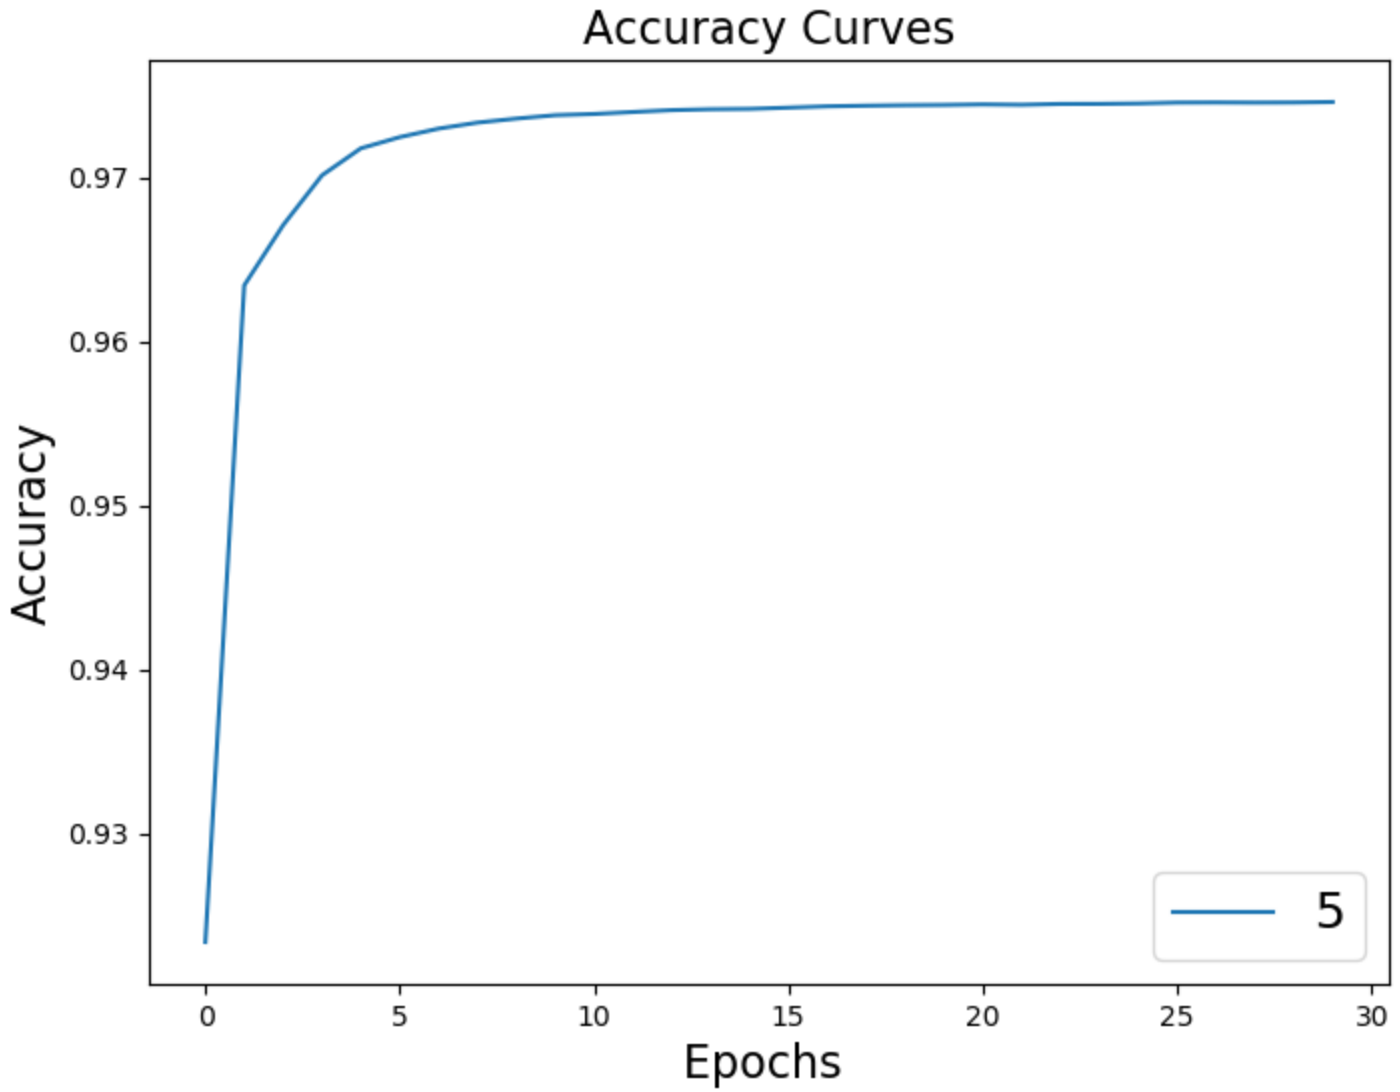
Accuracy Curves
Accuracy
0.97
0.96
0.95
0.94
0.93
0
5
10
15
20
25
30
Epochs
5

Batch normalization

trénovanie $$bn(x) = \gamma \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$$

inferencia $$bn(x) = \gamma \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$$

$$\mu = \sum_{i=1}^{t} (1-\alpha)^{t-i} \mu_{B_i} \qquad \sigma^2 = \sum_{i=1}^{t} (1-\alpha)^{t-i} \sigma_{B_i}^2$$

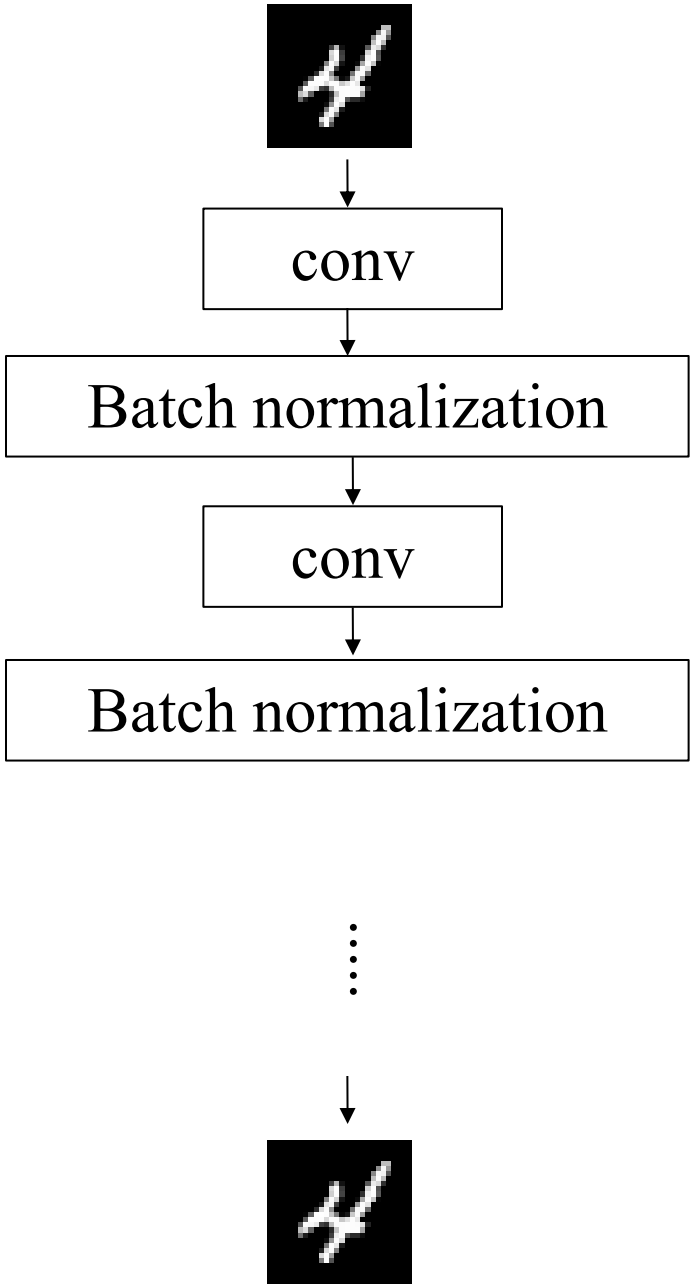
conv
Batch normalization
conv
Batch normalization

- Batch normalization

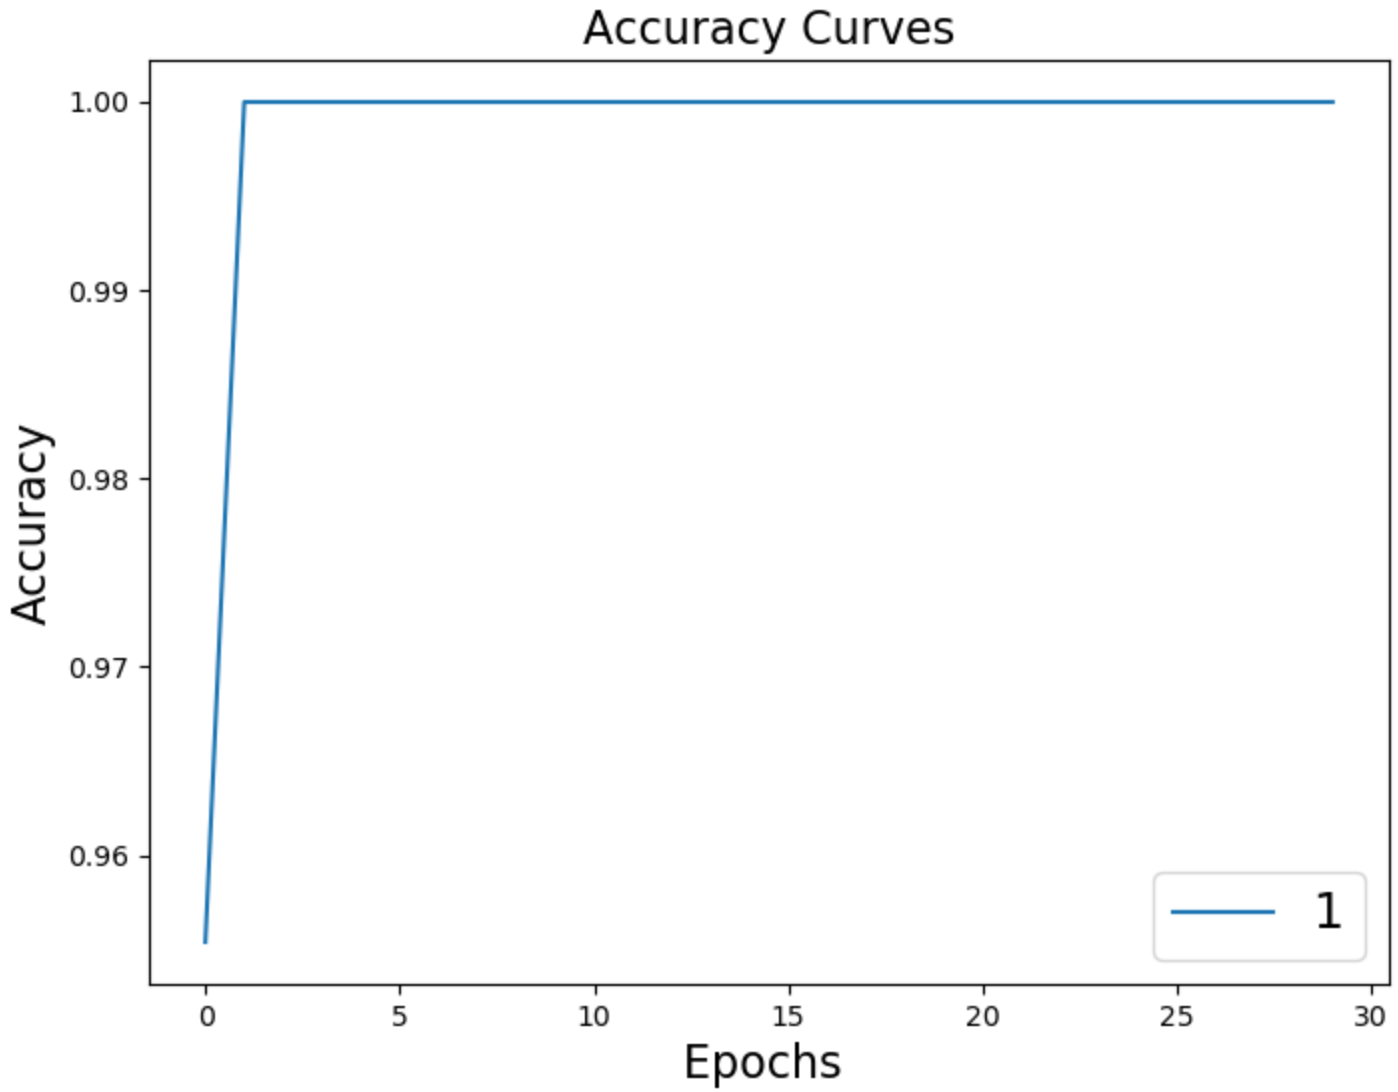

Reziduálne spojenie

Nehľadáme $f(x)$

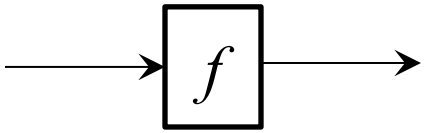

Ale doplnok $g := f(x) - x$

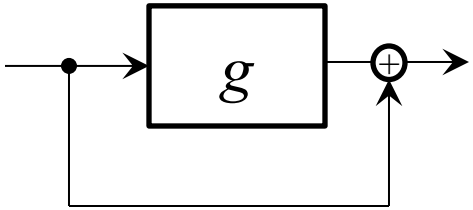

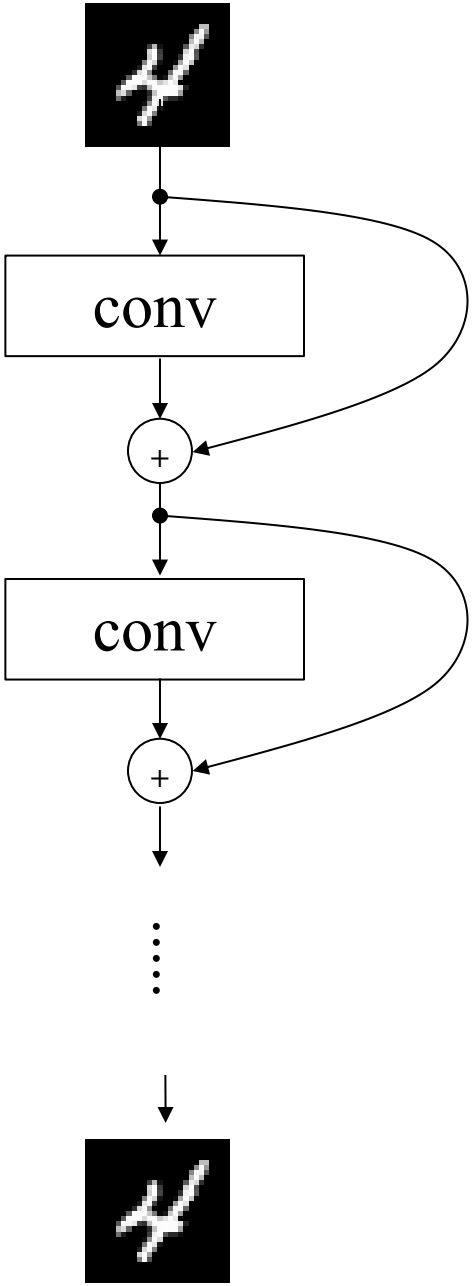
conv
+
conv
+

- Reziduály

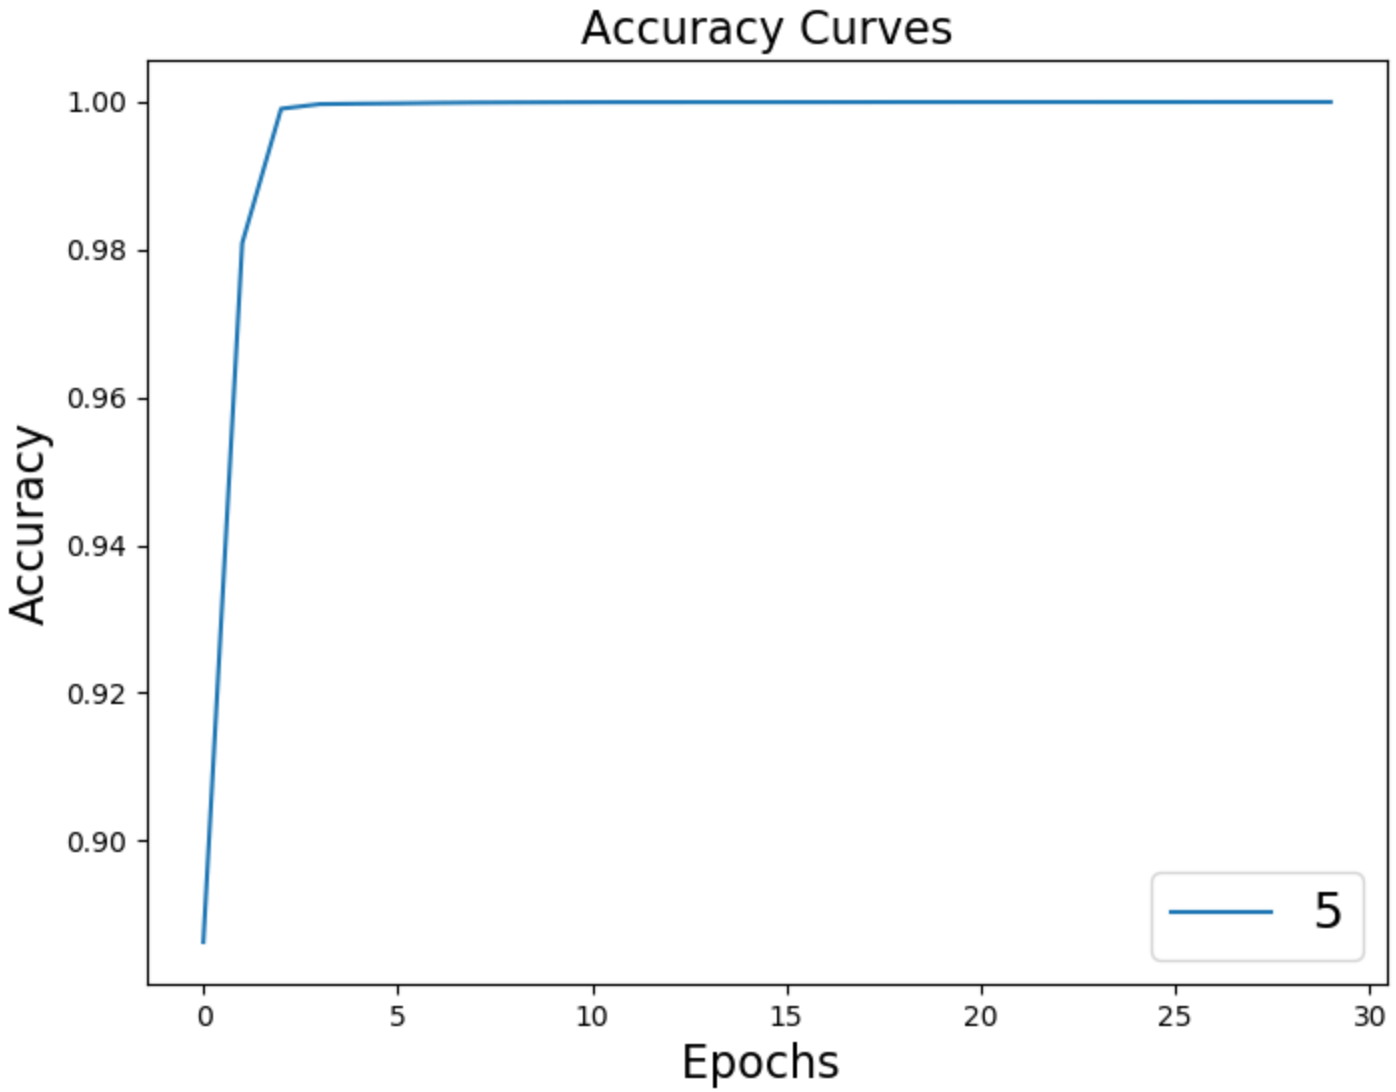
Accuracy Curves
1.00
0.98
0.96
0.94
0.92
0.90
Accuracy
0
5
10
15
20
25
30
Epochs
5

Augmentation

- Anotovať dataset je namáhavé, takže hľadáme cesty ako príklady z datasety rozmnožiť.
- Napríklad v datasete tvárí, nám vertikálny flip de facto zdvojnásobí dataset, lebo tváre nie sú úplne súmerné
- Operácie ktoré vyrábajú z jednej vzorky ďalšie (zväčšením, zmenšením, pootočením, posunutím, prevrátením, ...) nazývame augmentation

Sliding window algorithm

Každý klasifikátor sa dá premeniť hrubou silou na detektor pomocou algoritmu používajúceho plávajúce okno:

- otestujeme všetky možné výskyty
- zosumarizujeme výskyty cez Non-Maximum Suppression

Detektor

Urobíme ho ako klasifikátor ktorý sa bude bude pozerať na rôzne miesta na obraze a klasifikovať tam kúsky hľadaných objektov (zameraním sa na kúsky si zároveň zväčšujeme dataset)

Implementujeme ho ako perceptron

To vieme urobiť pomocou dvoch či viacerých blokov konvolučných vrstiev

YOLO Detektor (You Look Only Once)

- obraz pokryjeme neprekrývajúcimi sa regiónmi
- nad každým regiónom vykonáme klasifikáciu a regresiu a zosumarizujeme výsledky

- Klasifikátor dáva pravdepodobnosť, že región patrí k detekovanému objektu
- Regressor dáva obdĺžnik obsahujúci objekt, ktorého je región súčasťou

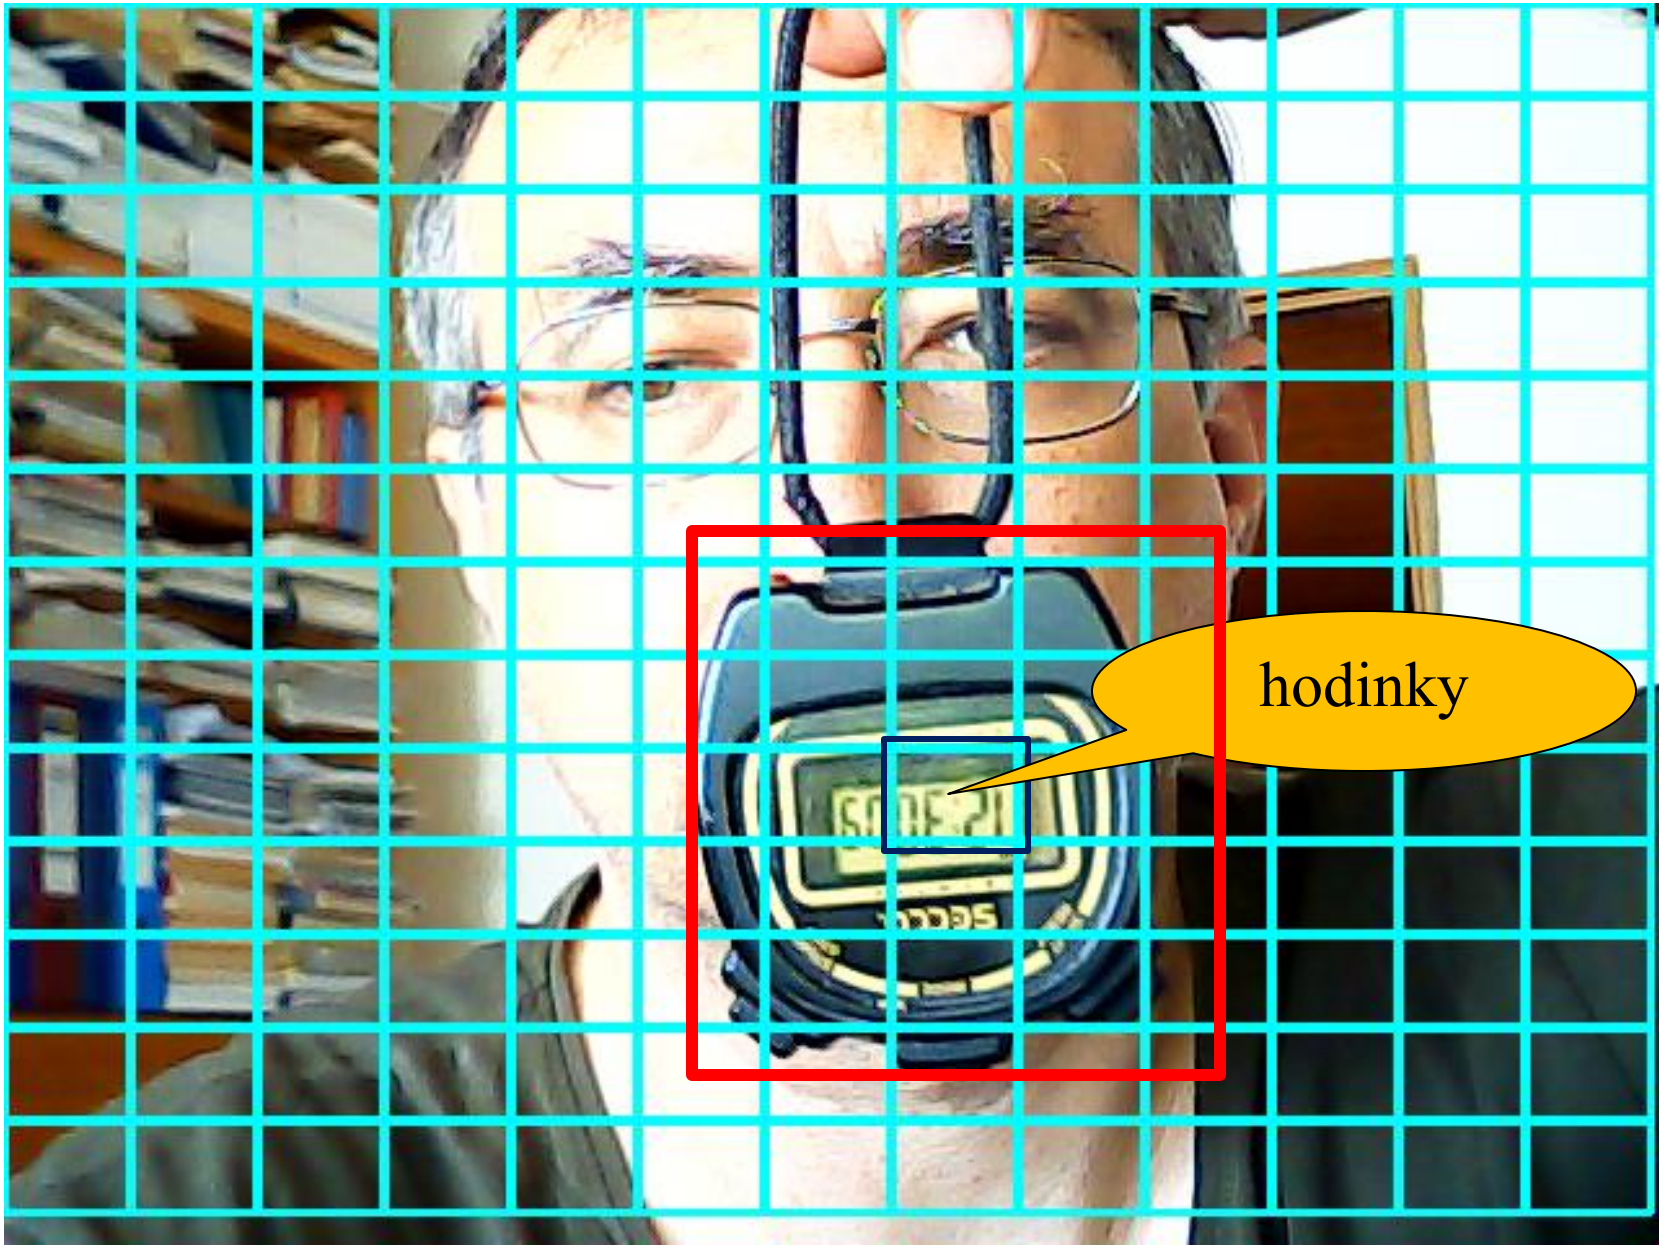
hodinky

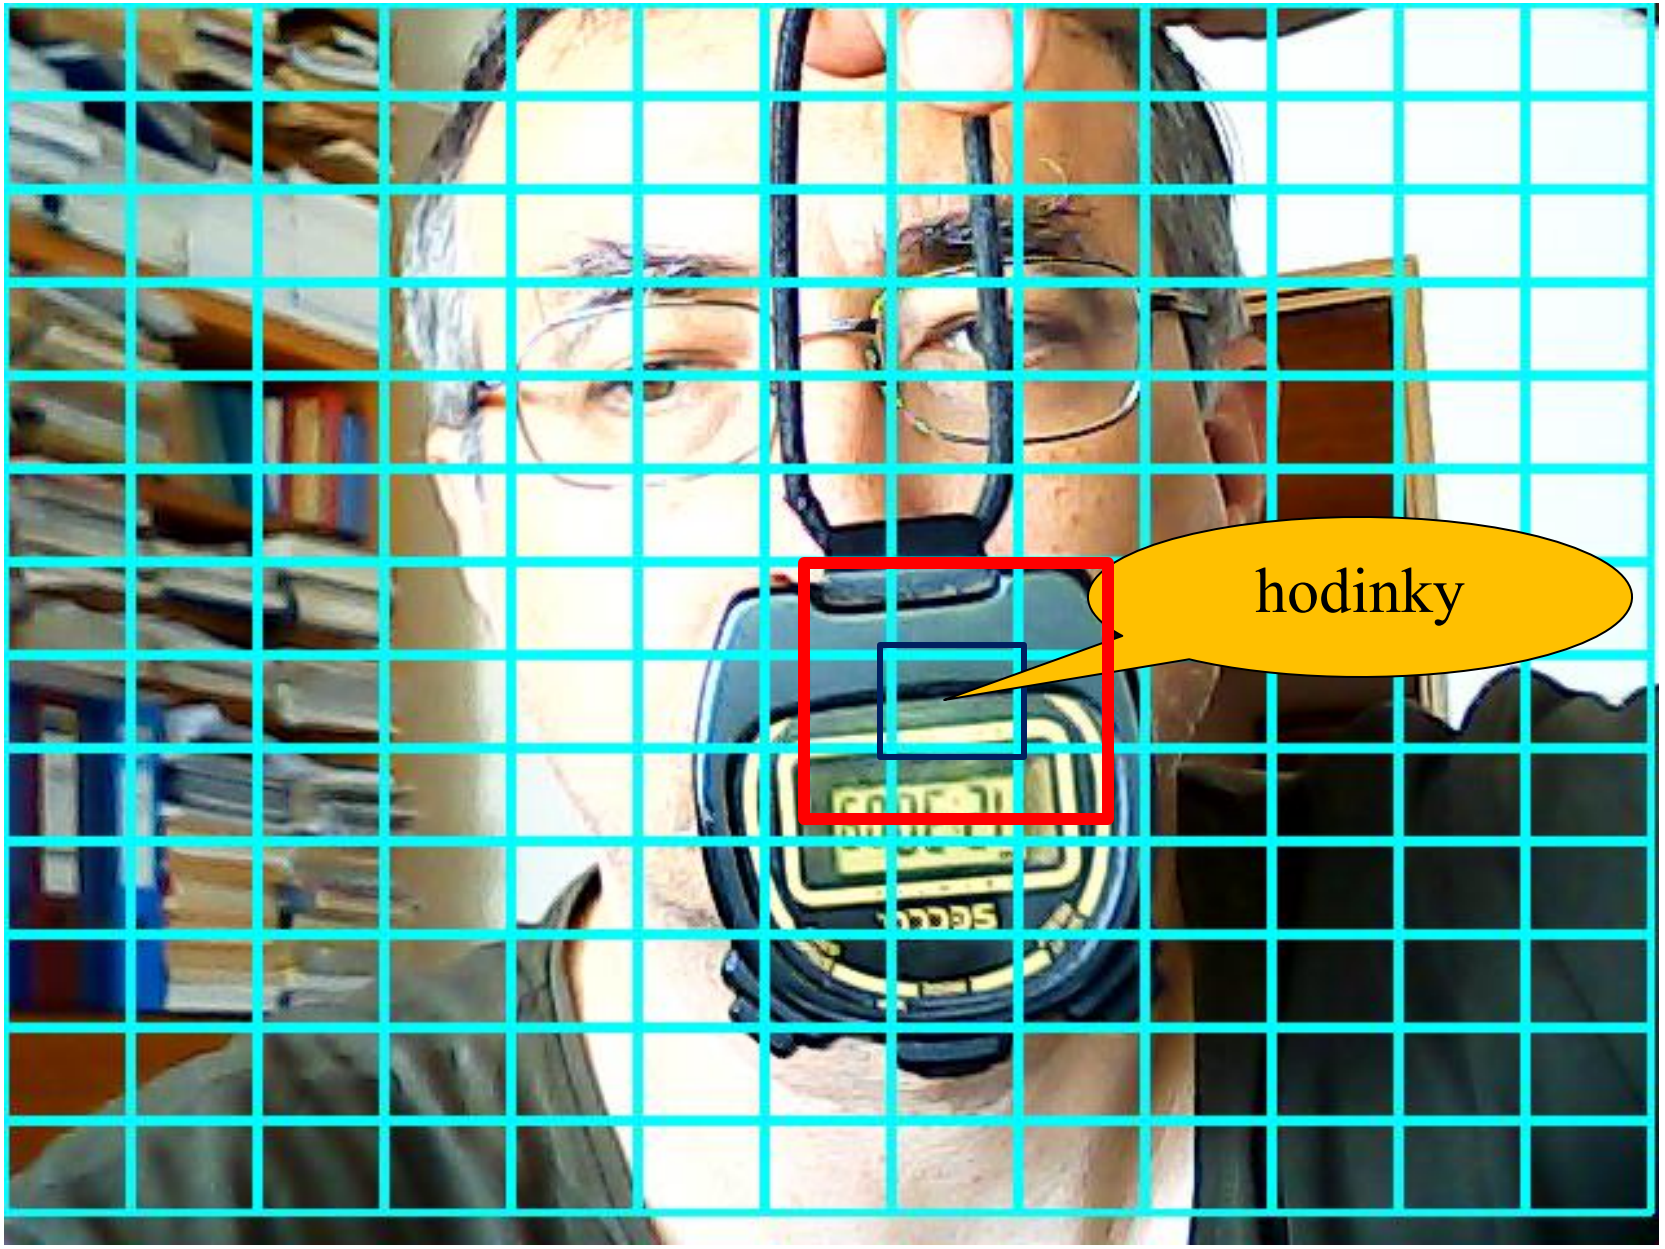
hodinky

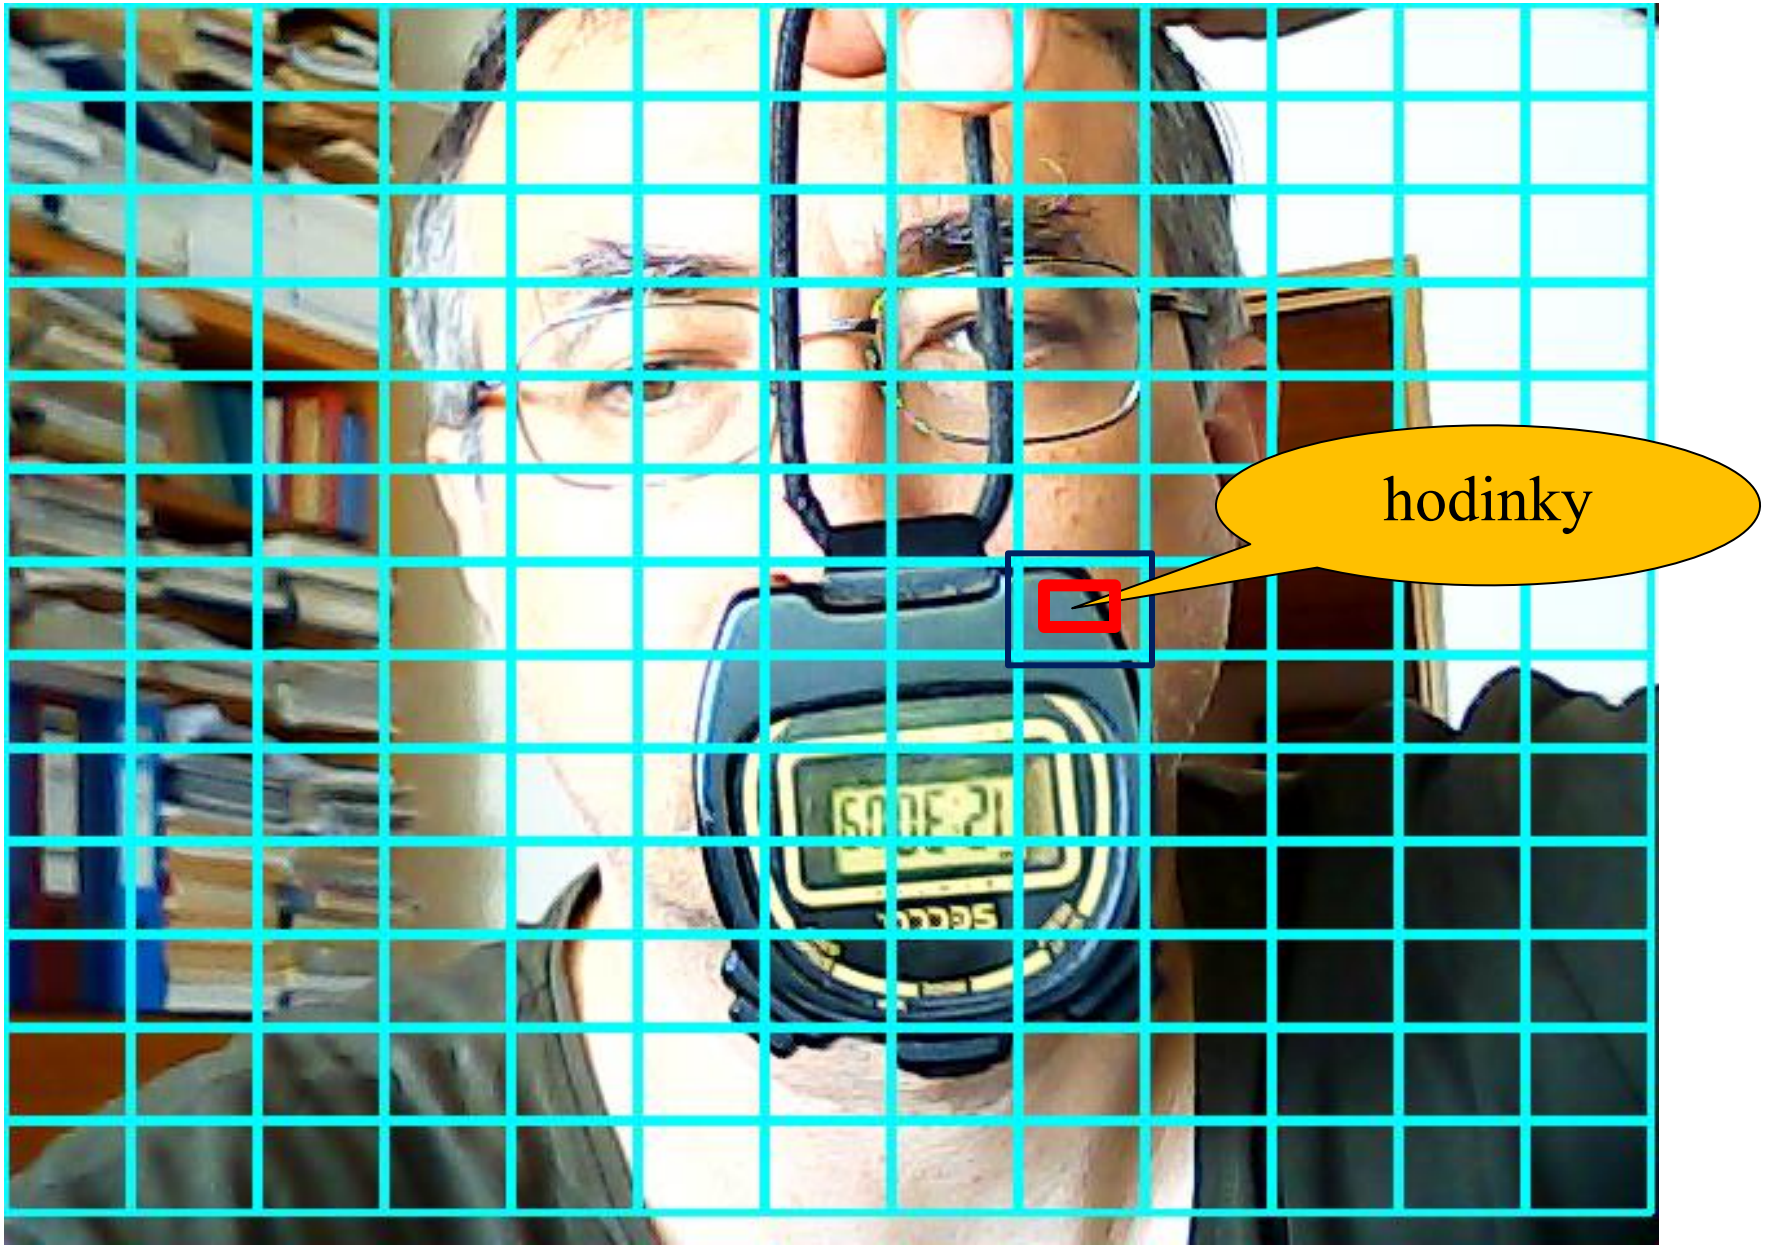
hodinky


tvár

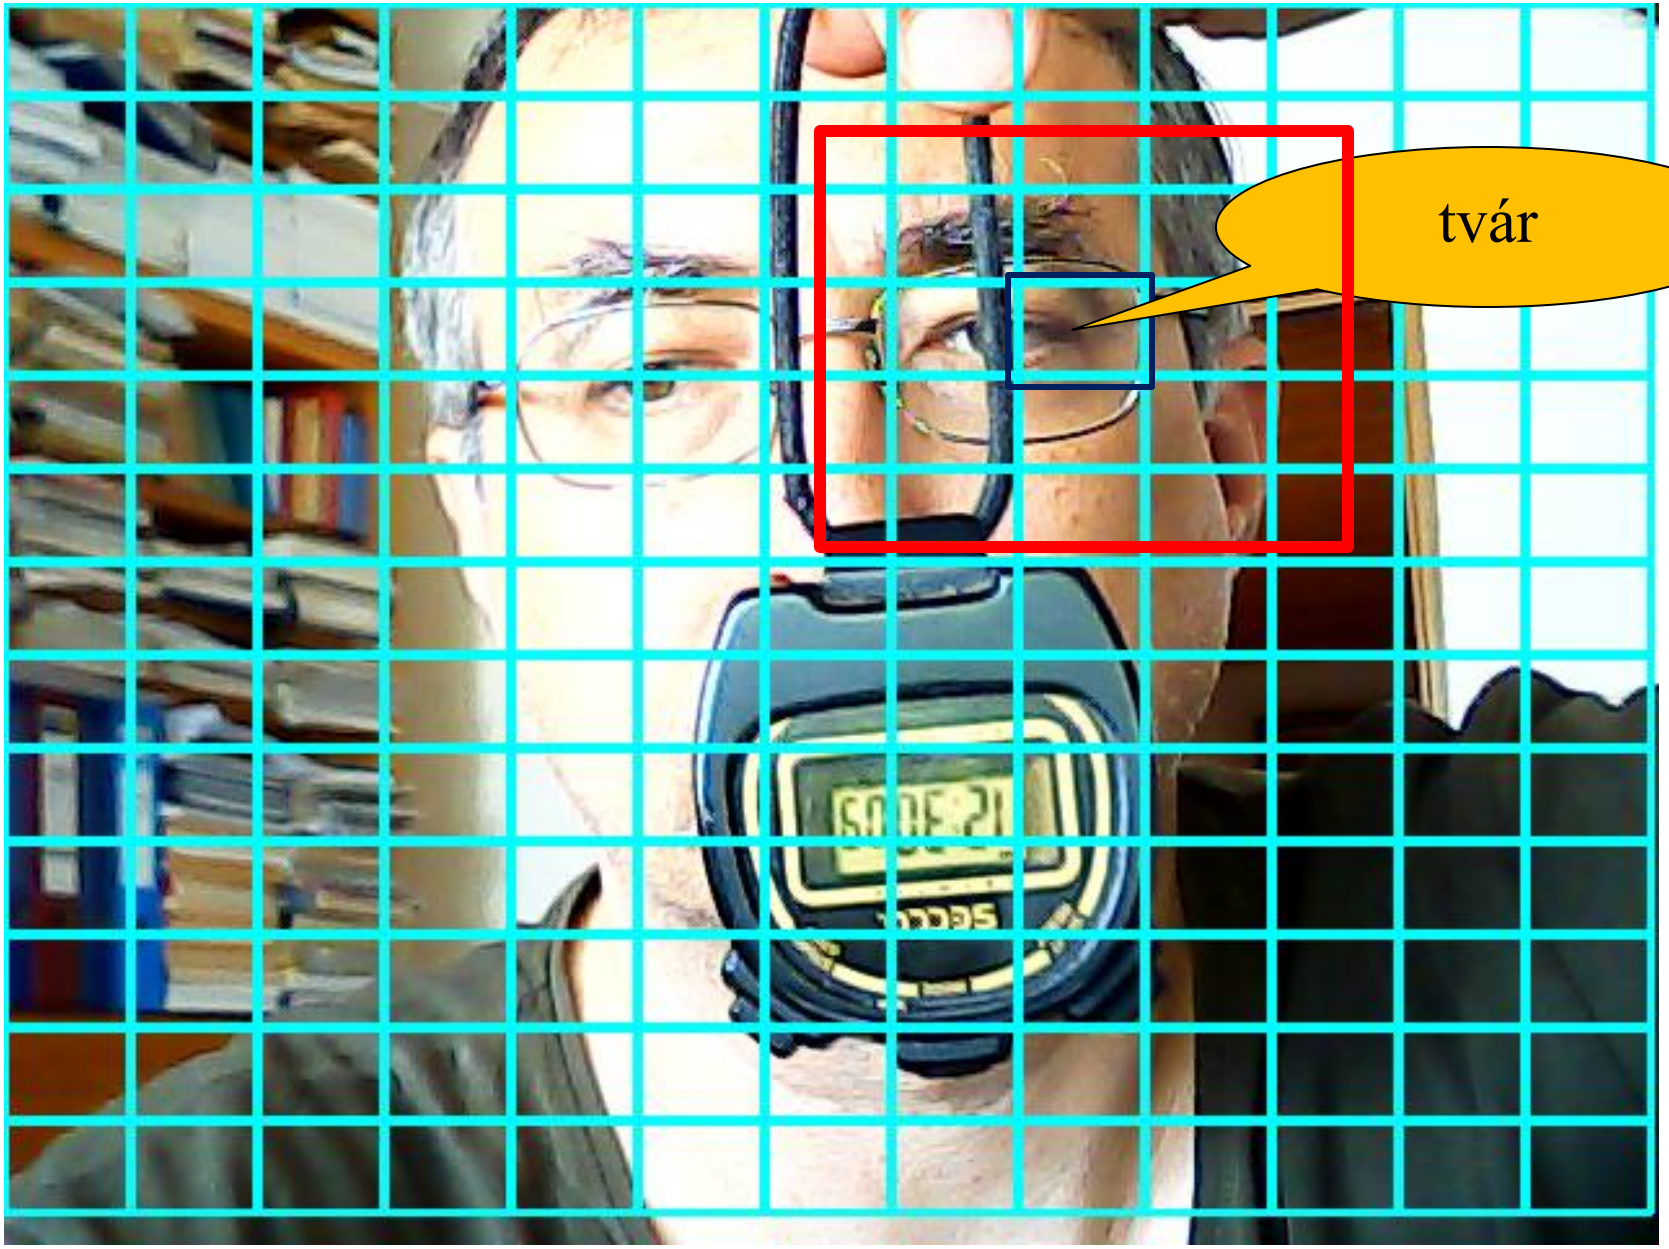
tvár

YOLO v1

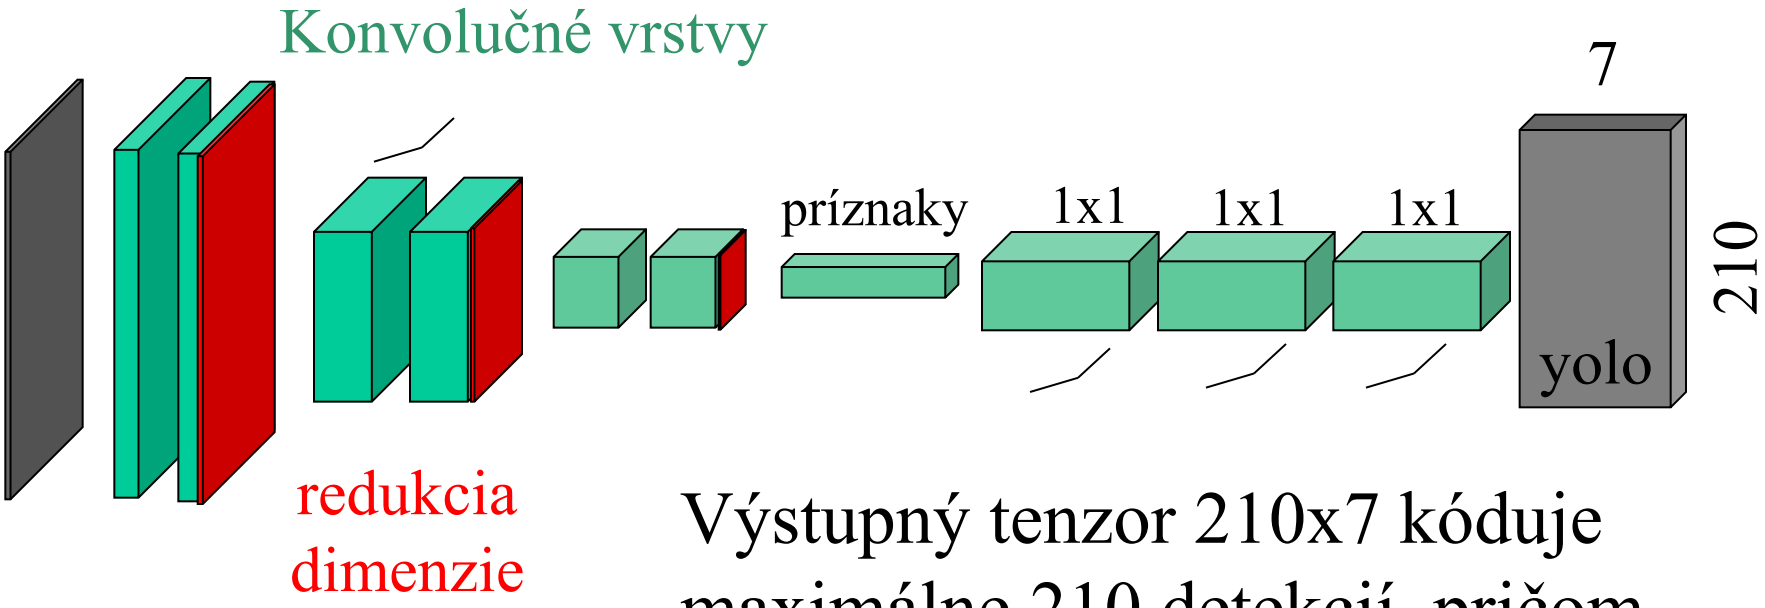

Výstupný tenzor 210x7 kóduje maximálne 210 detekcií, pričom každá obsahuje: relevantnosť, kategóriu, spoľahlivosť, x, y, w, a h

(sumarizáciu vykonáva špeciálny stavebný prvok zvaný yolo)

- Ak máme kúsok hodiniek v určitom regióne, zvyšuje ho pravdepodobnosť, že je aj v susedných regiónoch.
- Ako by sme mohli dosiahnuť, že paralelne pustené perceptrony budú kooperovať?
- Riešenie: Kernely 1x1 preložíme kernelmi 3x3

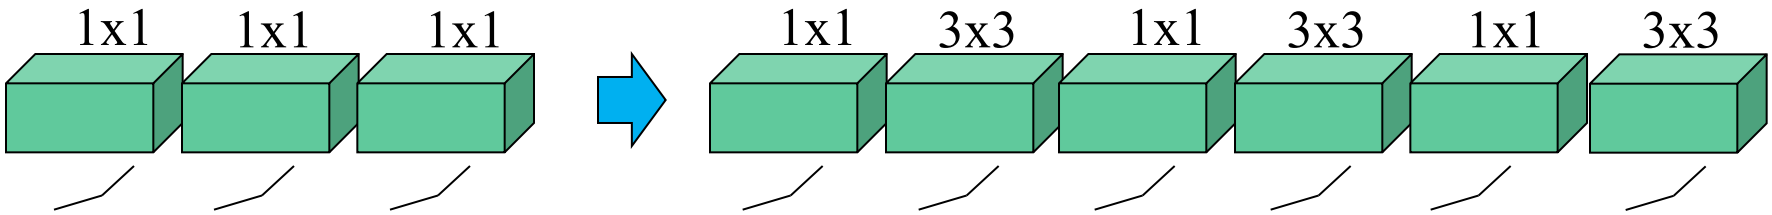

- Ako by sme mohli zohľadniť rôznu veľkosť objektov?
- Pustíme celé spracovanie paralelne viac krát pre 13x13, 26x26, a 52x52 regiónov

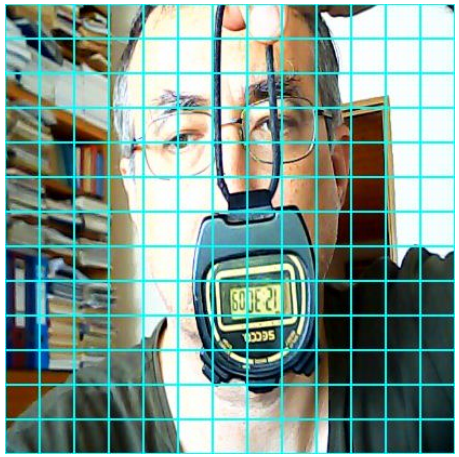
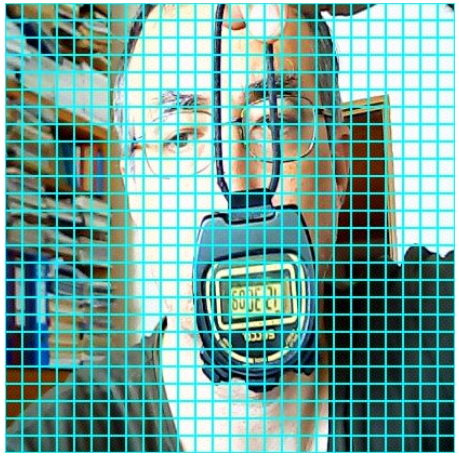
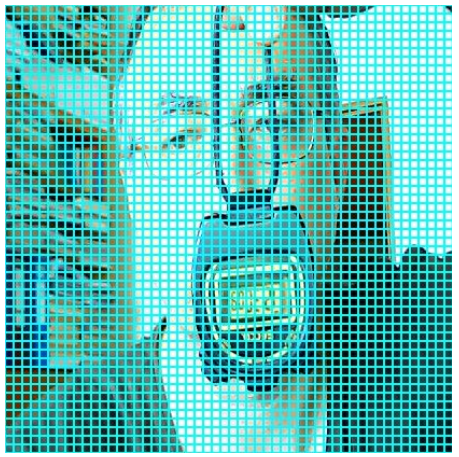

- V takom prípade aj menej detailné spracovanie môže radiť detailnejšiemu

YOLO v3 [Redmon, Farhadi 2018]

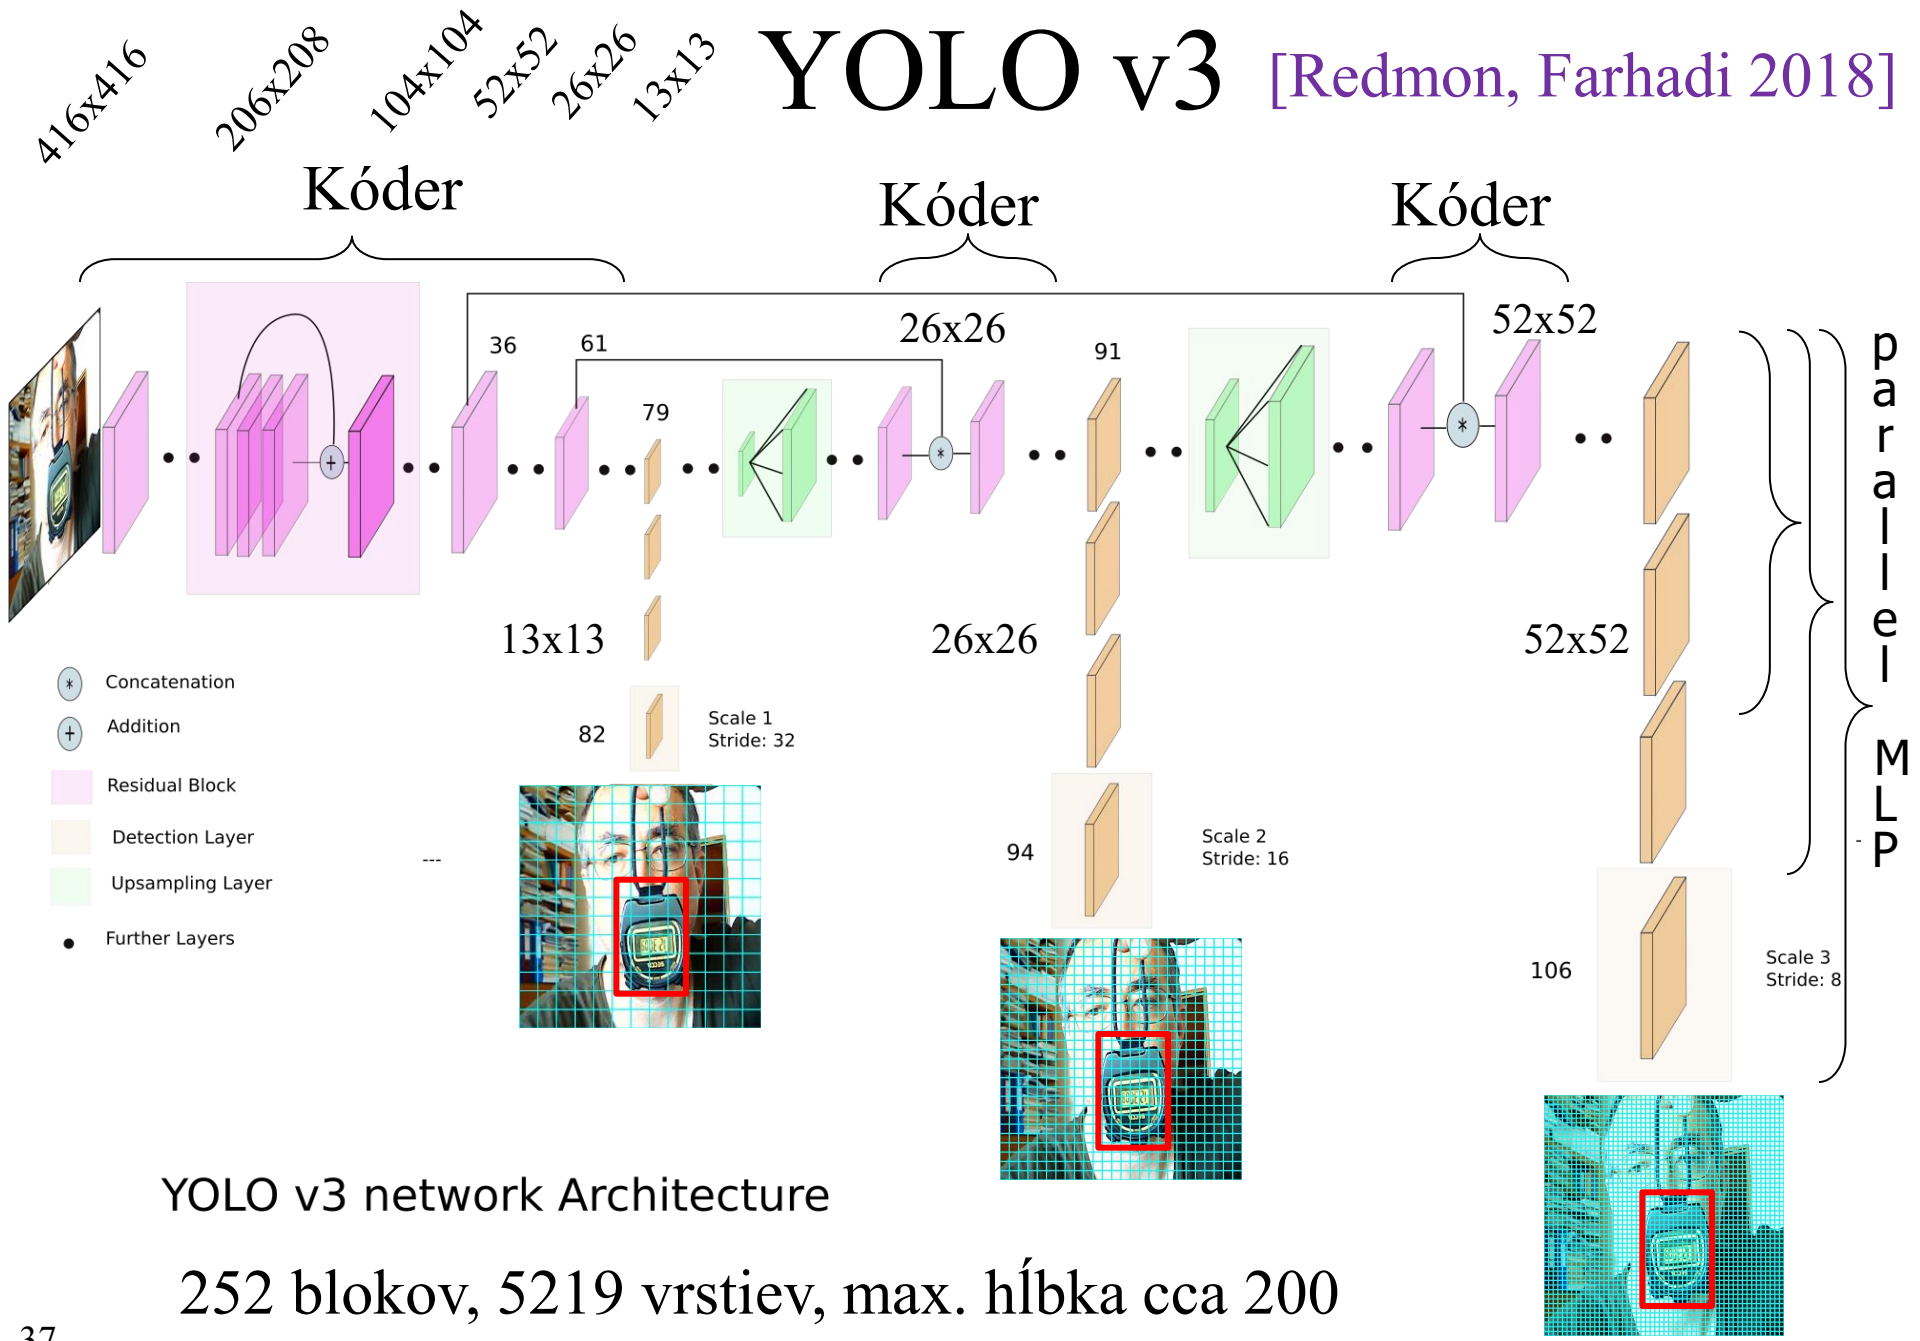

YOLO v3 network Architecture

252 blokov, 5219 vrstiev, max. hĺbka cca 200

Trénovanie hlbokých sietí

- Hlboké siete dokážu mať sofistikovanú architektúru, ale trénujú sa oveľa ťažšie (problém miznúceho gradientu pri spätnom šírení)
- Preto do takýchto sietí vkladáme stavebné prvky, ktoré trénovanie podporujú. YOLO v3 využíva reziduálne spojenia

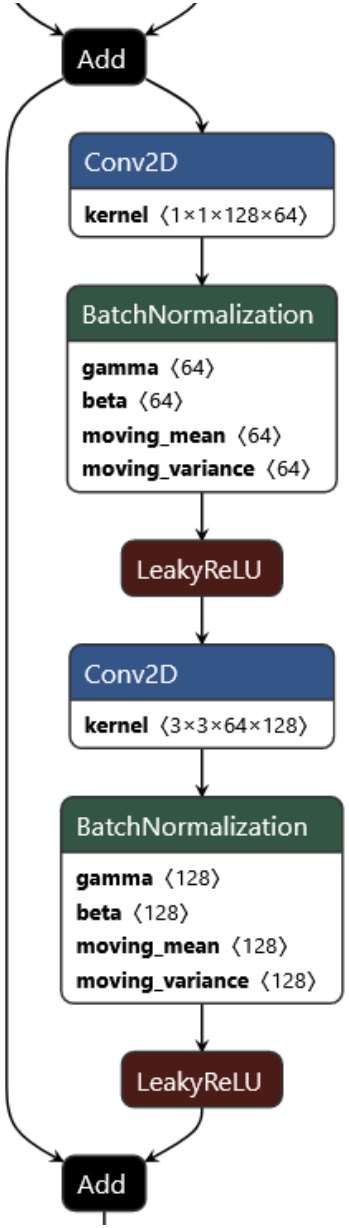

Normalizácia dávky

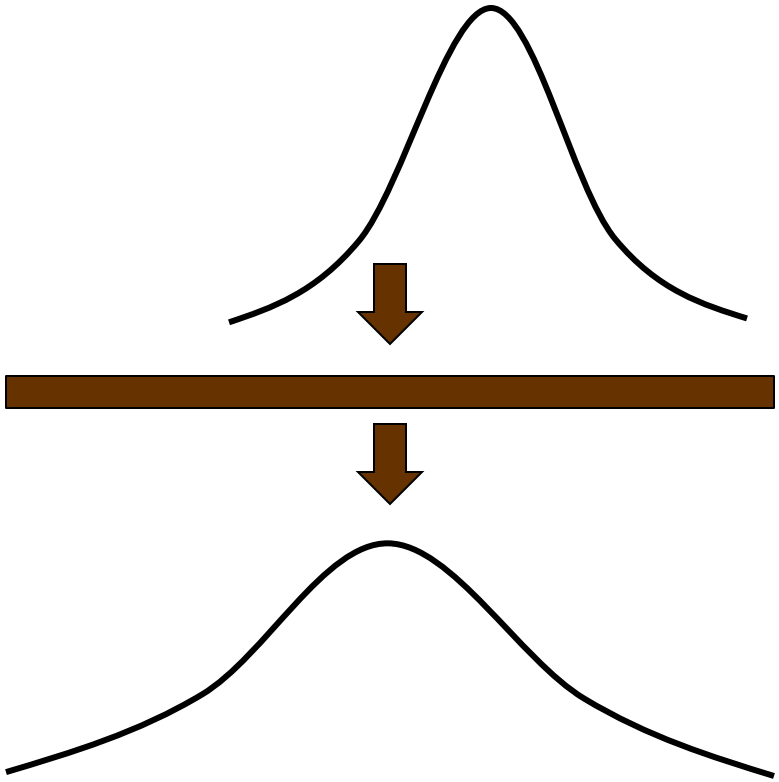

- Aby bolo trénovanie dostatočne rýchle, hlboké siete používajú sigmoidálne aktivácie len na výstupe a vnútri používajú ReLU
- ReLU ale nie je sigmoidálna a nedá sa s ňou implementovať aproximátor
- Preto pred (alebo za) ReLU vkladáme normalizáciu dávky

YOLO v3 schéma

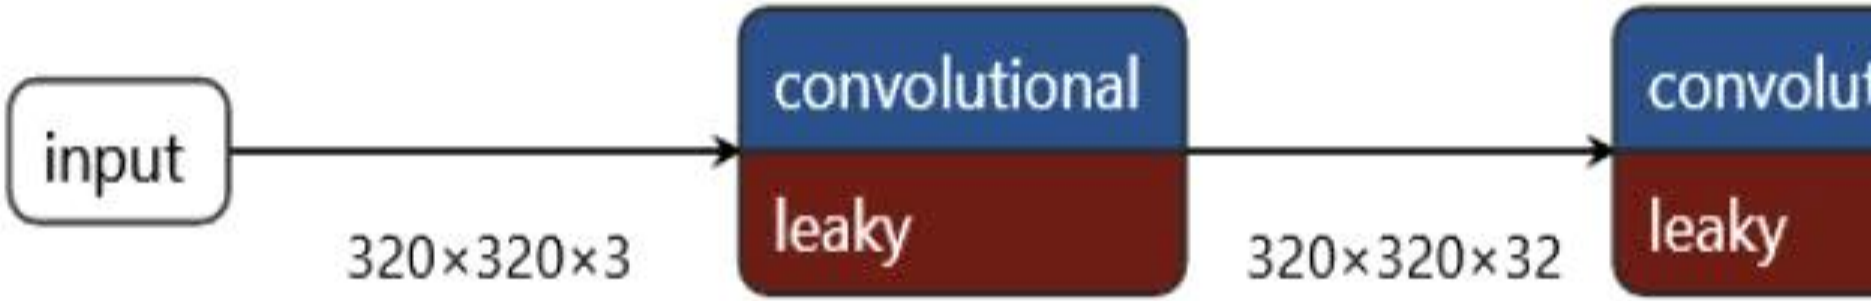

YOLO v3 - výstup

- 13x13x255, 26x26x255, 52x52x255
- Každý perceptron dáva tri detekcie pre tri kotvy, 3 x 255 hodnôt = 3 x 3 x 85
- Každá detekcia dáva 85 hodnôt = 4+1+80 obsahujúcich:

  4 … x, y, w, h

  1 … spoľahlivosť

  80 … pravdepodobnosť príslušnosti k jednej z 80 kategórii

Ukotvenia

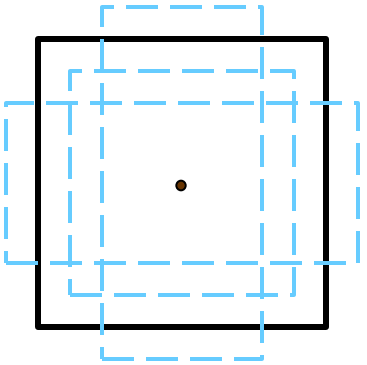

- Každá detekcia vyjadruje x,y,w, a h relatívne k určitému ukotveniu. YOLO v3 využíva tri ukotvenia pre každú z troch veľkostí objektov (dohromady deväť), každé s rôznym pomerom strán
- Ukotvenia v YOLO v3:
  [116x90, 156x198, 373x326] (výstup 52x52)
  [30x61, 62x45, 59x119] (výstup 26x26)
  [10x13, 16x30, 33x23] (výstup 13x13)

Transférové učenie

YOLO v3 poskytuje predtrénovaný model pre 80 kategórii z dátovej vzorky COCO:
person, bicycle, car, motorbike, aeroplane, bus, train, truck, boat, traffic light, fire hydrant, stop sign, parking meter, bench, bird, cat, dog, horse, sheep, cow, elephant, bear, zebra, giraffe, backpack, umbrella, handbag, tie, suitcase, frisbee, skis, snowboard, sports, ball, kite, baseball bat, baseball glove, skateboard, surfboard, tennis racket, bottle, wine glass, cup, fork, knife, spoon, bowl, banana, apple, sandwich, orange, broccoli, carrot, hot dog, pizza, donut, cake, chair, sofa, pottedplant, bed, diningtable, toilet, tvmonitor, laptop, mouse, remote, keyboard, cell phone, microwave, oven, toaster, sink, refrigerator, book, clock, vase, scissors, teddy bear, hair drier, toothbrush

Pri trénovaní pre vlastné dátové vzorky, nezačíname s náhodnými parametrami, ale parametrami predtrénovaného modelu.

Trénovanie YOLO v3 https://youtu.be/CPGR26Fhcro

https://youtu.be/ENYEUUbqjIE

Spracovanie videa