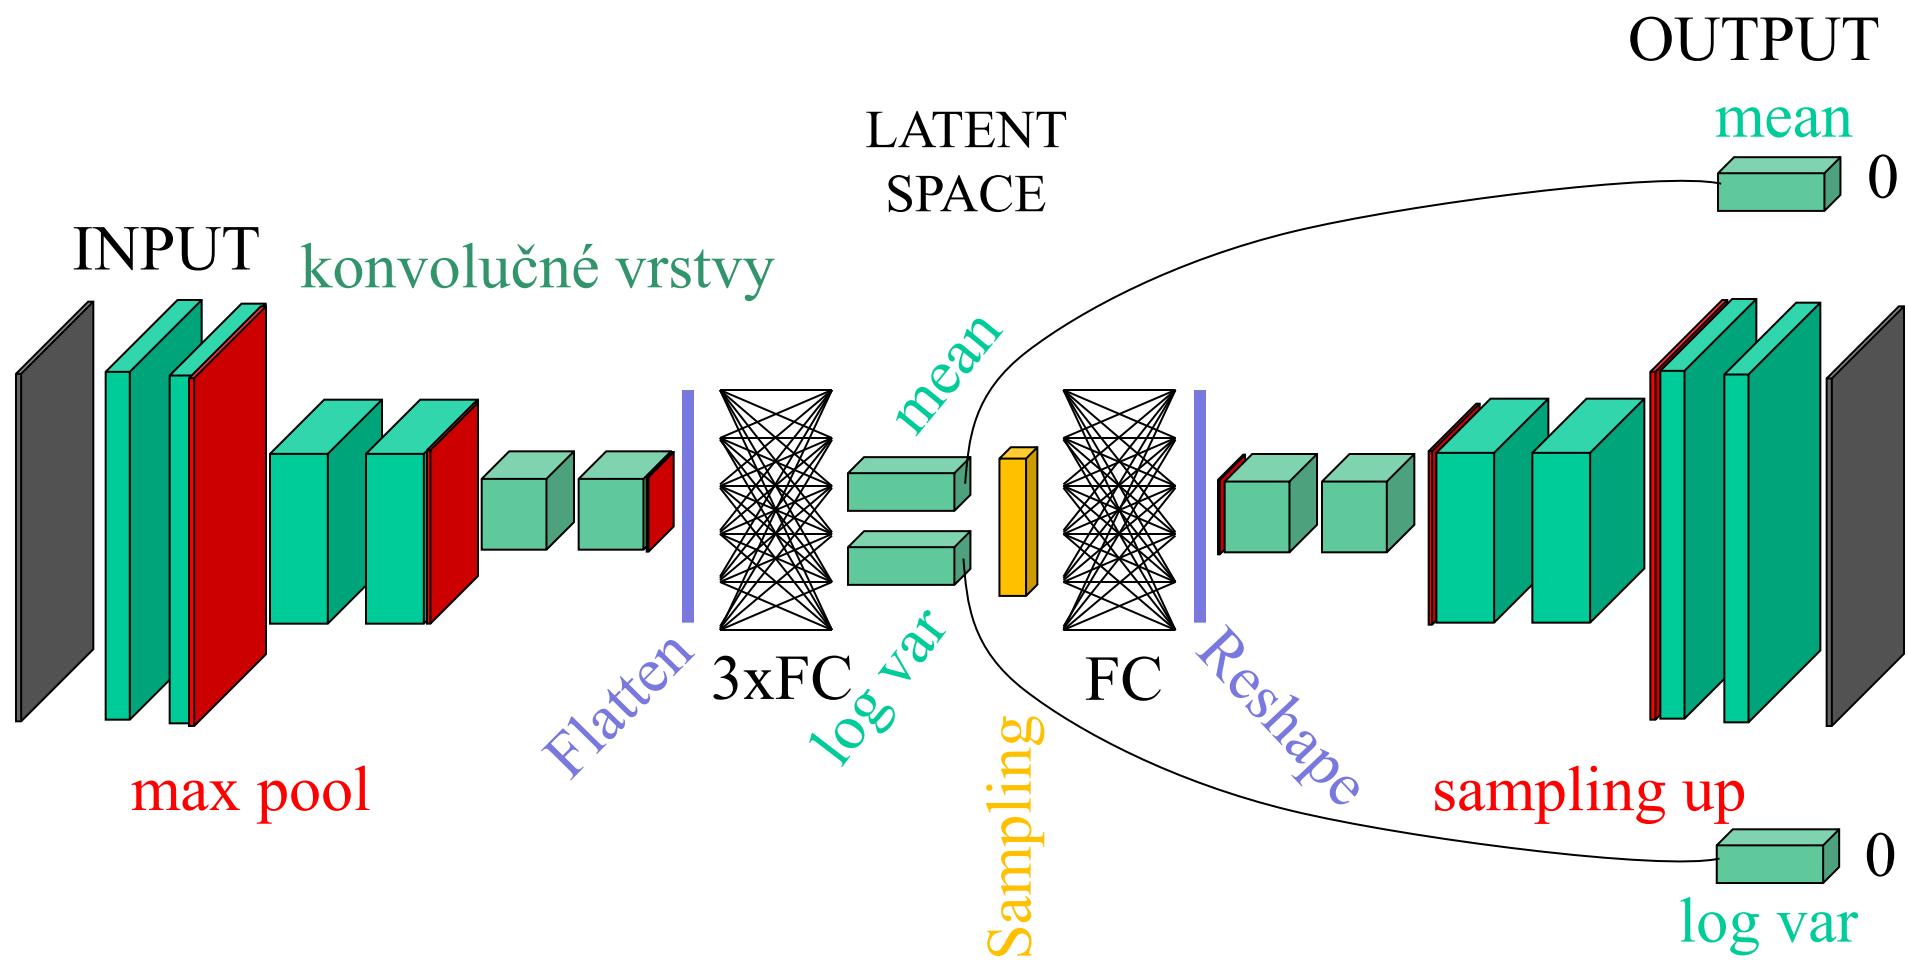
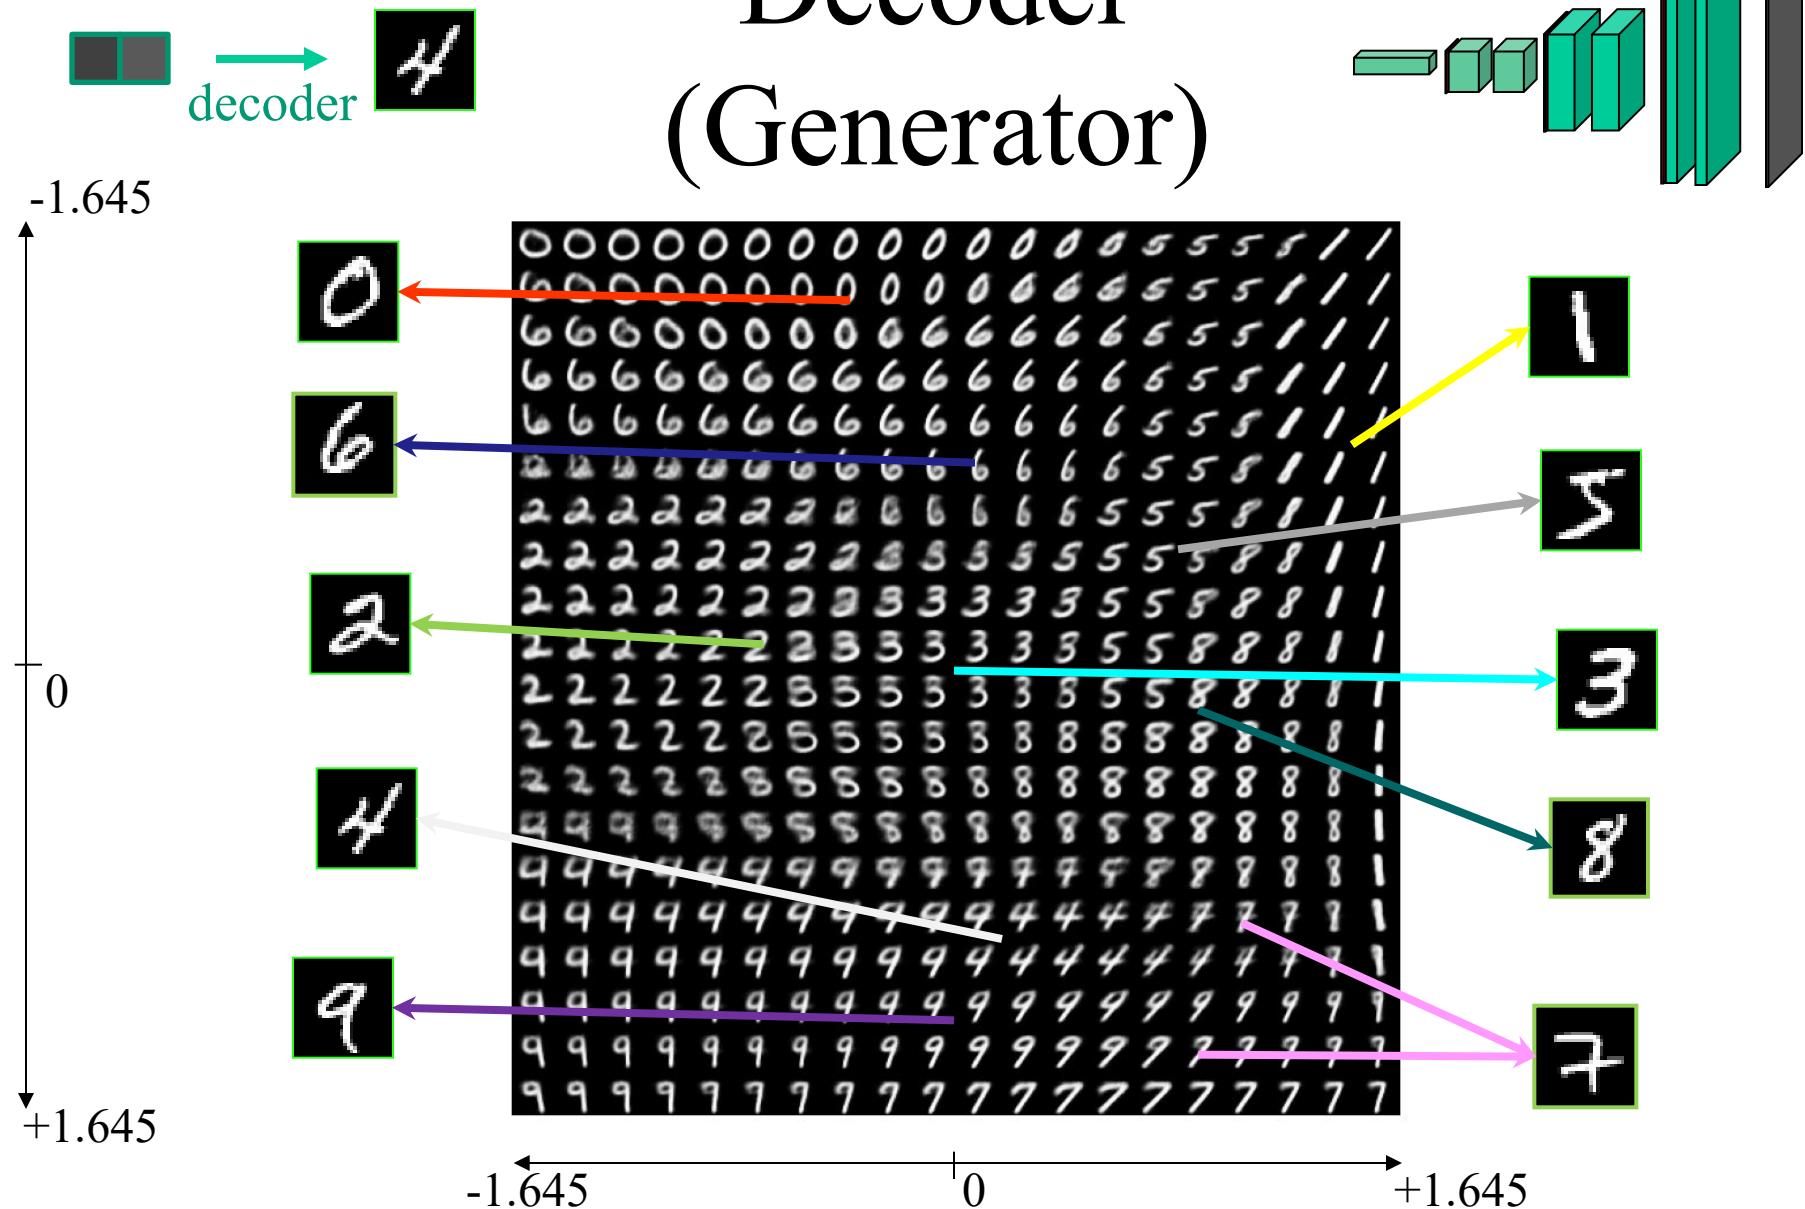


Variational autoencoder

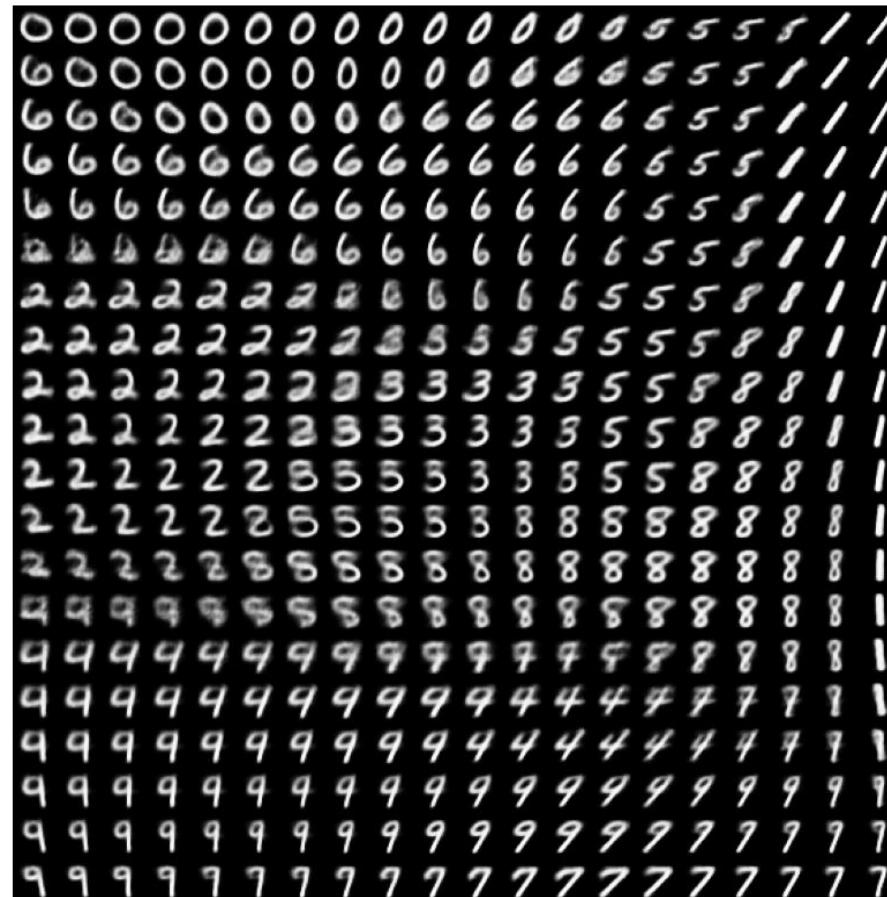


Decoder (Generator)



CNN

vnútro hyperkocky



Podobnosť:euklidovská vzdialenosť

Euklidovská podobnosť

vektor (u_1, u_2, \dots, u_N) má **velkosť**

$$|u| = \sqrt{(u_1^2 + u_2^2 + \dots + u_N^2)}$$

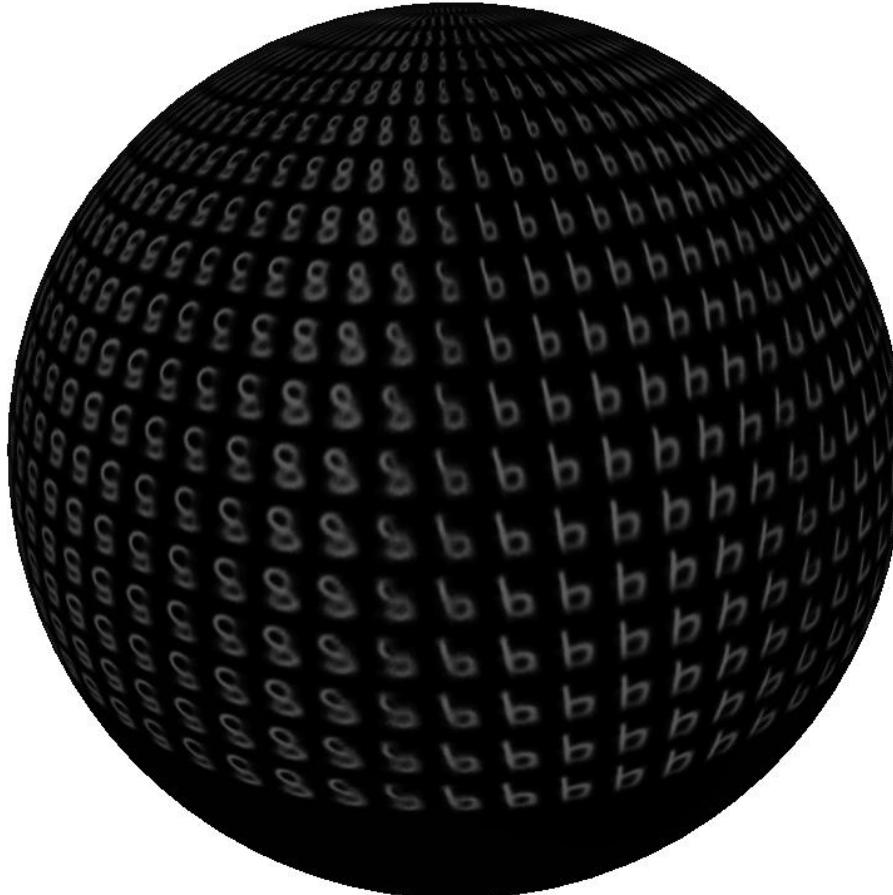
(odmocnina súčtu druhých mocnín koordinátov)

dva vektory (u_1, u_2, \dots, u_N) a (v_1, v_2, \dots, v_N) majú

podobnosť $|u - v|$

Transformery

Povrch hypergul'e



podobne
Zemi aj tu
sú pohoria a
priekopy

Podobnosť: cosínusová podobnosť

Kosínusová podobnosť

vektor (u_1, u_2, \dots, u_N) má **velkosť**

$$|u| = \sqrt{u_1^2 + u_2^2 + \dots + u_N^2}$$

dva vektorov (u_1, u_2, \dots, u_N) a (v_1, v_2, \dots, v_N) zvierajú uhol ϕ

$$\cos \phi = \frac{u_1 v_1 + u_2 v_2 + \dots + u_N v_N}{|u| |v|}$$

(kosinus uhla je podiel **skalárneho súčinu** koordinátov a súčinu velkostí vektorov)

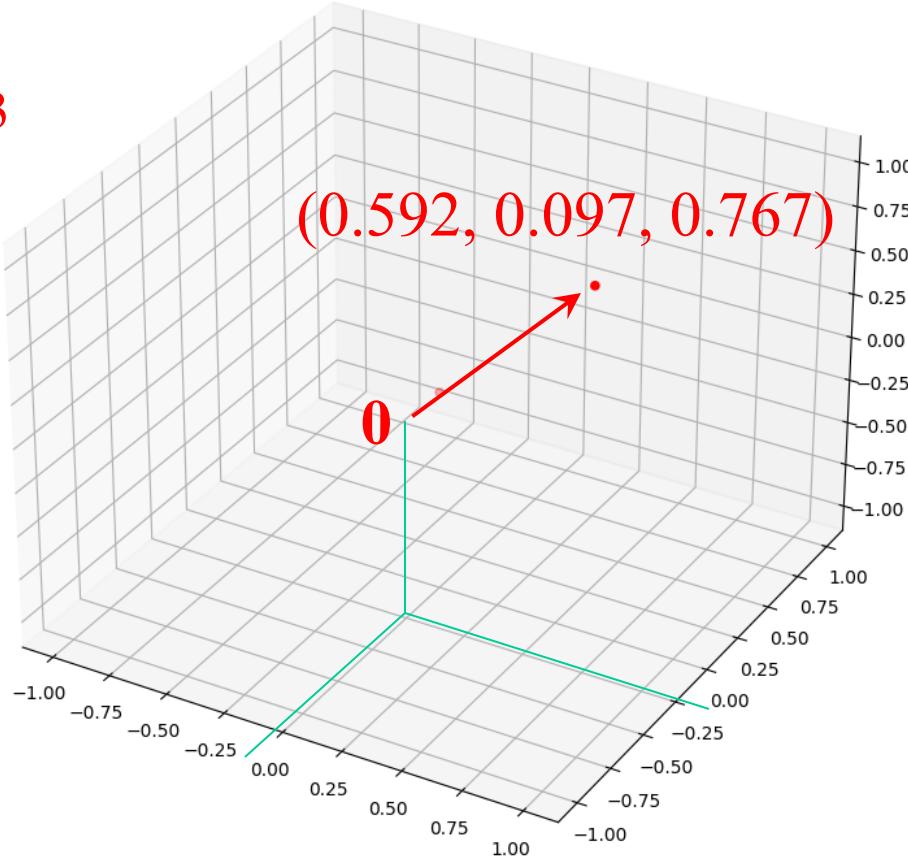
$$\cos \phi = 1$$

$$\cos \phi = 0$$

$$\cos \phi = -1$$

Embedding (Vnorenie)

$N = 3$

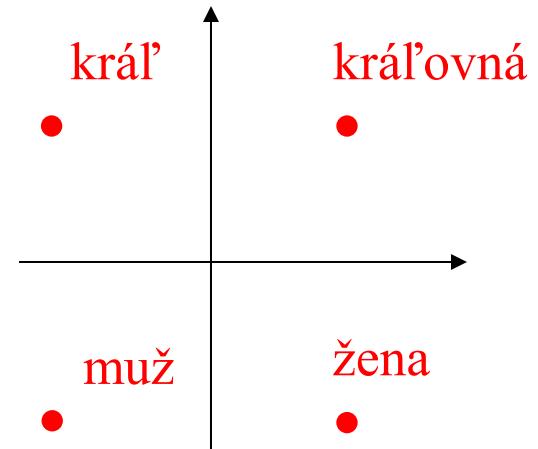


Význam reprezentujeme vektorom (či bodom) v mnohorozmernom priestore príznakov

Reprezentácia slova vektorom

slovník

kráľ	(-1,1)
kráľovná	(1,1)
muž	(-1,-1)
žena	(1,-1)



v slovníku máme 4 slová a každému priradujeme vektor dimenzie 2
máme dva príznaky: pohlavie a vládnutie

Aritmetika významov

Kto sa má k žene tak, ako kráľ' ku kráľovnej ?

Riešime rovnicu:

$$x - \text{žena} = \text{kráľ} - \text{kráľovná}$$

$$x - (1, -1) = (-1, 1) - (1, 1)$$

$$x - (1, -1) = (-2, 0)$$

$$x = (-2, 0) + (1, -1)$$

$$x = (-1, -1)$$

$$x = \text{muž}$$

slоварík

kráľ	(-1,1)
kráľovná	(1,1)
muž	(-1,-1)
žena	(1,-1)

Aritmetika významov

Kto sa má k žene tak, ako kráľ' ku kráľovnej ?

Riešime rovnicu:

$$\begin{aligned}x - \text{žena} &= \text{kráľ} - \text{kráľovná} && \text{Embedding (Vnorenie)} \\x - (1, -1) &= (-1, 1) - (1, 1) \\x - (1, -1) &= (-2, 0) \\x &= (-2, 0) + (1, -1) \\x &= (-1, -1) \\x &= \text{muž}\end{aligned}$$

slовар

kráľ	(-1,1)
kráľovná	(1,1)
muž	(-1,-1)
žena	(1,-1)

Wipeout (Vynorenie)

Ako nájst' správne hodnoty jednotlivých vektorov automaticky ?

Zoberieme korpus:

V kráľovskom dvore si kráľ s kráľovou vychutnávali plesy a hudobné predstavenia. Muž a žena, ktorí boli oddaní manželským záväzkom, sa stali kráľom a kráľovou v ich vlastnej domácnosti. Na námestí sa stretol muž so ženou a spolu snívali o tom, že by mohli byť kráľom a kráľovou svojej vlastnej krajiny. Kráľ so svojou kráľovou prechádzali rozkvitnutým záhradným labyrintom, objímajúc sa pod každým rozkvitnutým stromom. Muž sa rozhadol, že chce byť kráľom svojho osudu, a žena ho podporovala, aby sa stala jeho vernou kráľovou. Na večernom bankete si kráľ so svojou kráľovou vymieňali nežné pohľady a tajné úsmevy. V dedine si obyvatelia vybrali muža a ženu, aby sa stali kráľom a kráľovou na miestnom jarmoku. Kráľovná pozvala mladú ženu do svojho paláca a pomohla jej pripraviť sa na večernú hostinu s kráľom. Muž a jeho milovaná žena spolu snívali o kráľovských príbehoch, ktoré by mohli prežiť. Na slávnostnom obrade bola mladá žena korunovaná za kráľovnú a jej muž sa stal kráľom. ...

a spočítame ako často sa jedno slovo vyskytuje v kontexte druhého (t.j. v texte maximálne tri slová pred ním alebo za ním)

Ako nájst' správne hodnoty jednotlivých vektorov automaticky ?

Dostaneme tabuľku početnosti
a v ideálnom prípade dostaneme:

	kráľ	královná	muž	žena
kráľ	44	22	22	0
královná	22	44	0	22
muž	22	0	44	22
žena	0	22	22	44

Ako nájst' správne hodnoty jednotlivých vektorov automaticky ?

Dostaneme tabuľku početností, ktorú môžeme znormalizovať a v ideálnom prípade dostaneme:

	kráľ	královná	muž	žena
kráľ	1	0.5	0.5	0
královná	0.5	1	0	0.5
muž	0.5	0	1	0.5
žena	0	0.5	0.5	1

Ako nájst' správne hodnoty jednotlivých vektorov automaticky ?

Dostaneme tabuľku početností, ktorú môžeme znormalizovať a v ideálnom prípade dostaneme:

	kráľ	královná	muž	žena
kráľ	1	0.5	0.5	0
královná	0.5	1	0	0.5
muž	0.5	0	1	0.5
žena	0	0.5	0.5	1



slovnik

kráľ	(1,0.5,0.5,0)
královná	(0.5,1,0,0.5)
muž	(0.5,0,1,0.5)
žena	(0,0.5,0.5,1)

a opäť tu platí:

$$\text{muž} - \text{žena} = \text{kráľ} - \text{královná}$$

$$(0.5, 0, 1, 0.5) - (0, 0.5, 0.5, 1) = (1, 0.5, 0.5, 0) - (0.5, 1, 0, 0.5)$$

$$(0.5, -0.5, 0.5, -0.5) = (0.5, -0.5, 0.5, -0.5)$$

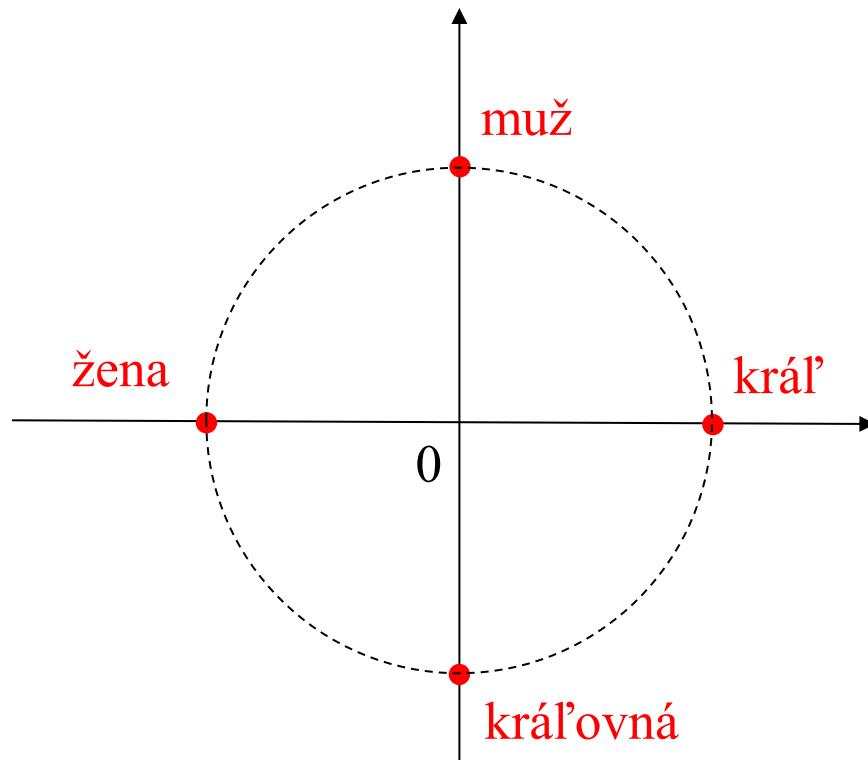
Je možné z automatického slovníka získať podobný tomu ručne urobenému?

Napodiv, odpoveď je kladná. Dokážeme to metódou lineárnej algebry zvanou PCA (Principal Component Analysis), keď jej dáme zredukovať dimenziu automatického slovníka (4) na 2

kráľ	(1,0.5,0.5,0)
kráľovná	(0.5,1,0,0.5)
muž	(0.5,0,1,0.5)
žena	(0,0.5,0.5,1)



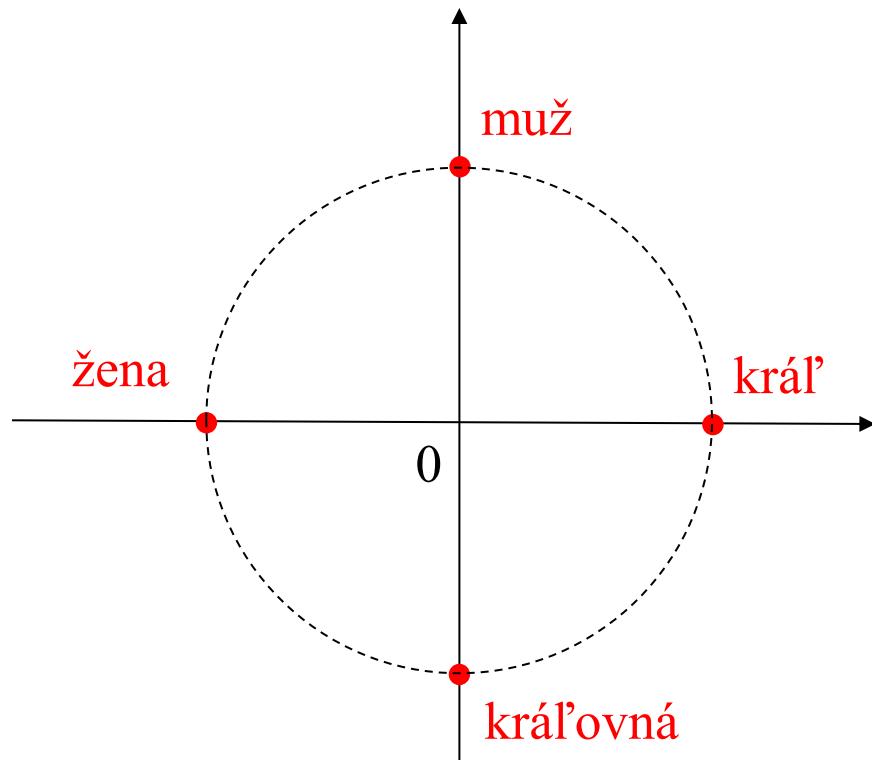
kráľ	(0.707, 0)
kráľovná	(0, -0.707)
muž	(0 ,0.707)
žena	(-0.707, 0)



Kosínusová podobnosť

muž je teraz podobnejší kráľovi ($\cos 90^\circ = 0$) viac než kráľovnej ($\cos 180^\circ = -1$) a najpodobnejší sebe ($\cos 0^\circ = 1$)

(to je vďaka tomu, že PCA
dáta vycentruje, t.j.
priemer je v nule a v tomto
prípade aj otočí o 45°)

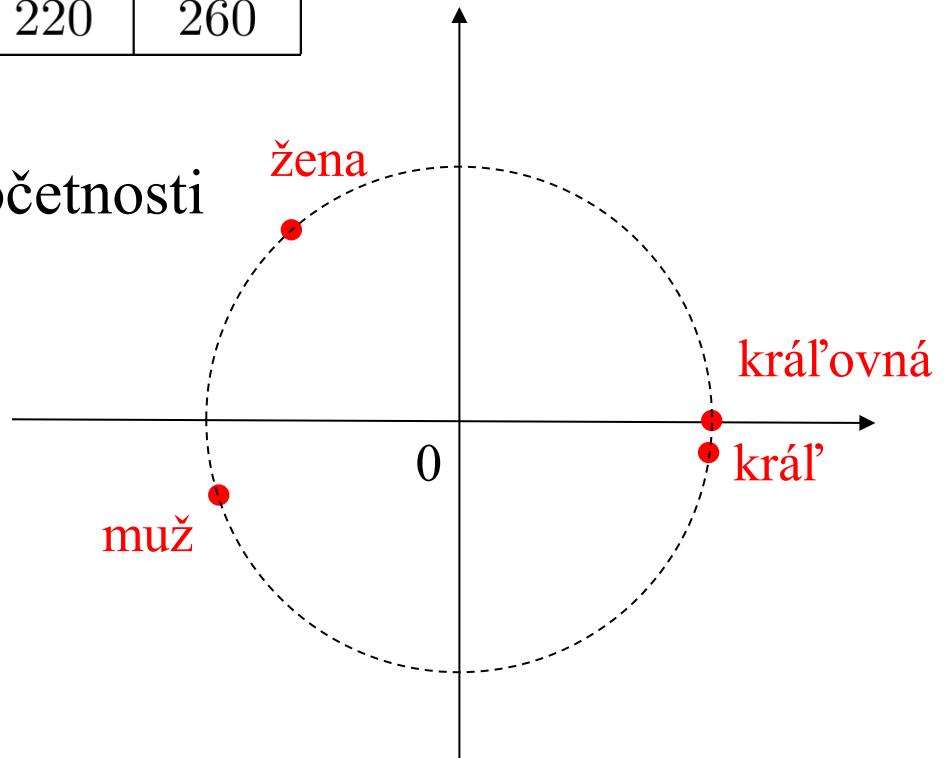


Čo by sa stalo keby početnosti v korpuse neboli optimálne?

	kráľ	královná	muž	žena
kráľ	44	18	12	5
královná	18	32	3	24
muž	12	3	440	220
žena	5	24	220	260

aplikujeme PCA priamo na početnosti a normalizujeme, dostaneme:

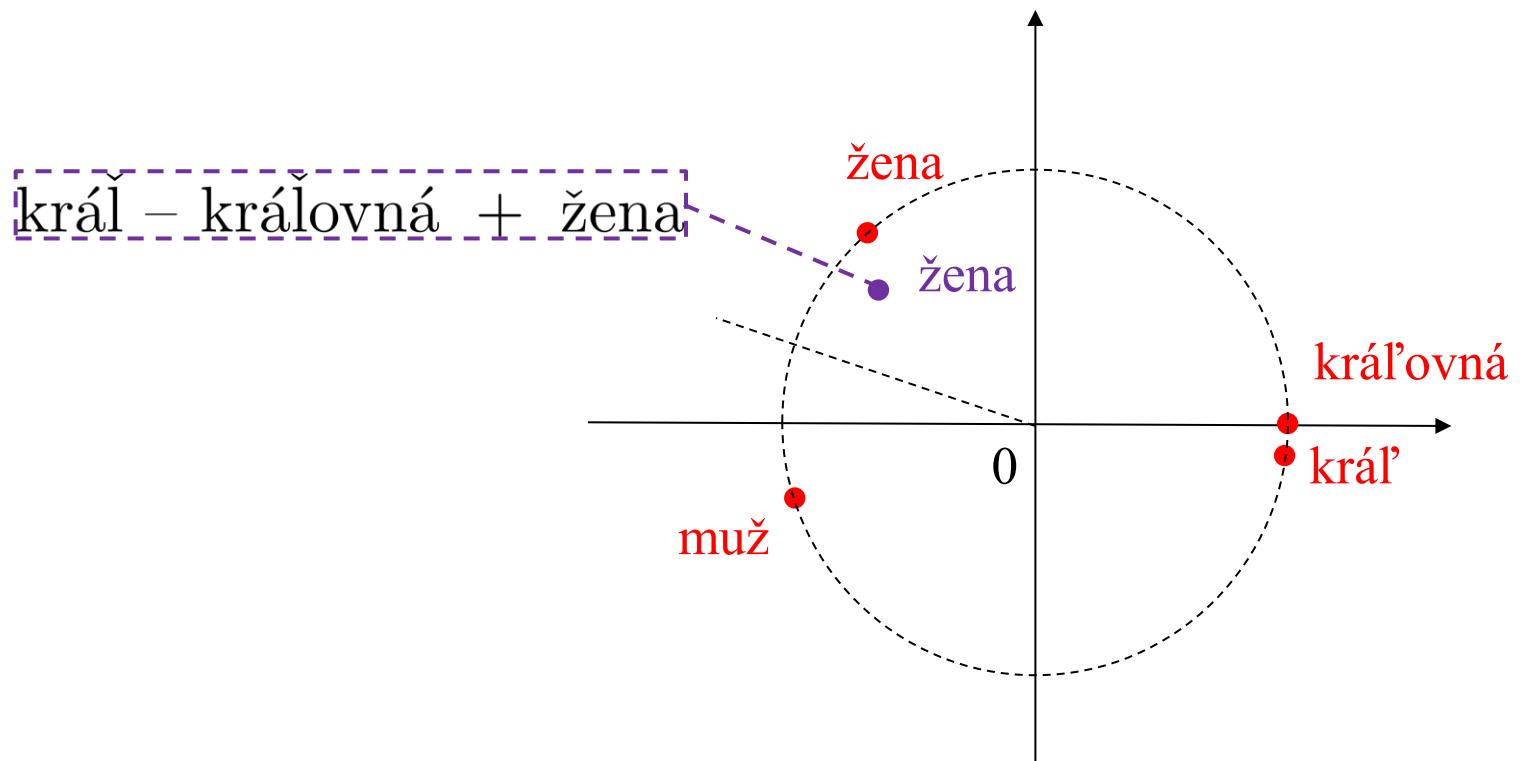
kráľ	(0.99, -0.14)
královná	(1.00, 0.00)
muž	(-0.98, -0.2)
žena	(-0.78, 0.63)



Proporcie máme dobré, ale aritmetika už nefunguje

Kto sa má k žene tak, ako kráľ' ku kráľ'ovnej ?

Aritmetika odpovie: žena



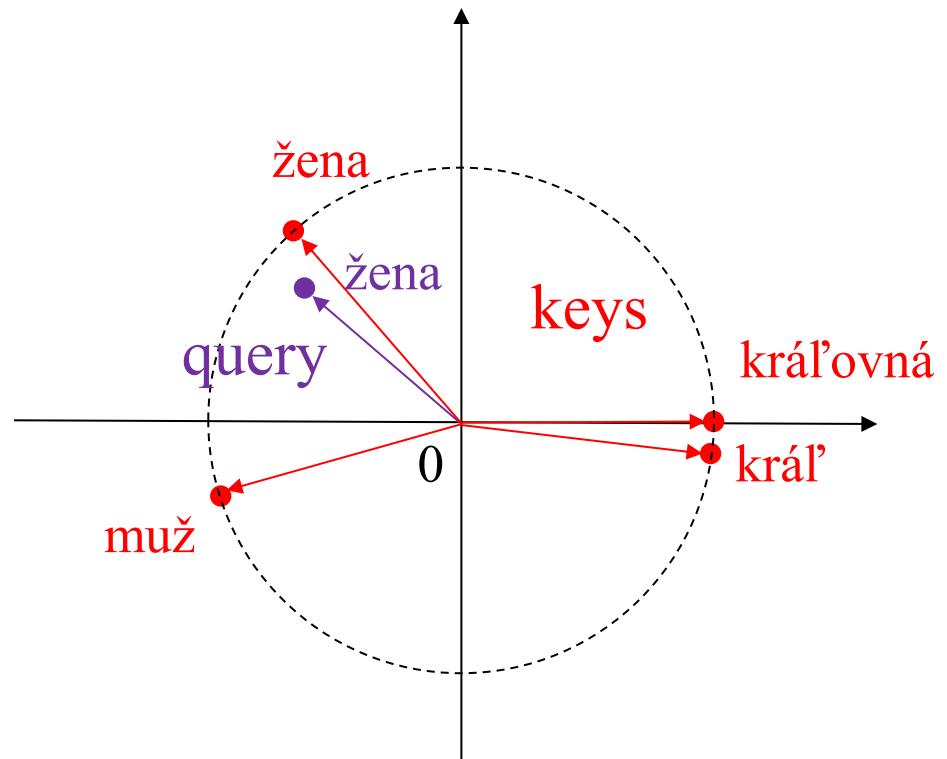
Wipeout (Vynorenie)

Výstupný embedding

Nepovie teda presne „žena“, len približne

Ako spočítame ku ktorému zo vzorov je výsledok najbližšie?

Hľadáme maximum skalárneho súčinu **query** so všetkými **keys**



Wipeout (Vynorenie)

Výstupný embedding

Máme keys $K = \begin{pmatrix} k_1 \\ k_2 \\ \dots \\ k_l \end{pmatrix}$ a query q

qK^T je vektor skalárnych súčinov q s k_i

Hľadáme teda $\arg \max_i qK^T$

Pokial' chceme pravdepodobnosti $\text{softmax}(qK^T)$
pre každú kategóriu:

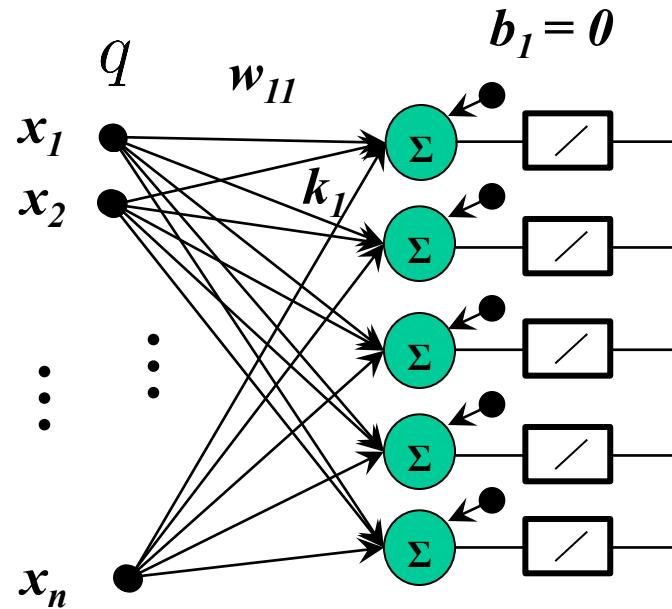
Implementácia Wipeout-u

Počet vstupov x_i
= dimenzia priestoru

Počet neurónov
= počet kl'účov

Kl'úče sú váhy
 $k_j = w_{1j}, w_{2j}, \dots$

Biasy sú nulové
Aktivácia lineárna



Lineárna projekcia

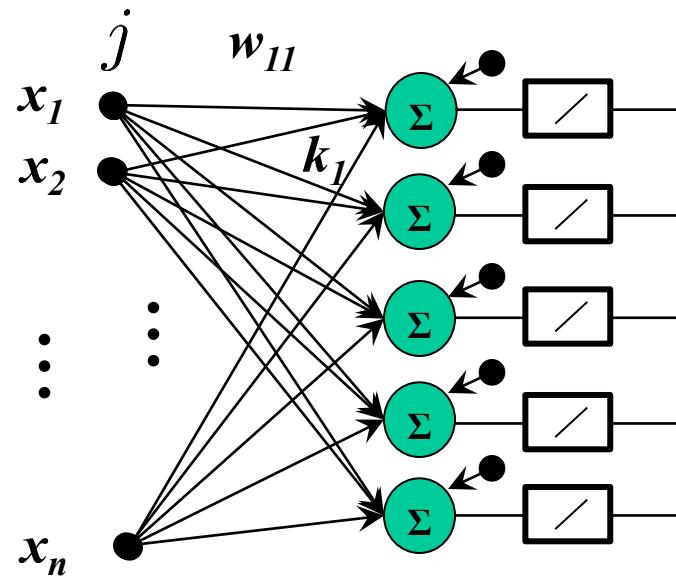
qK^T
Skalárne súčiny
query s kl'účmi

Implementácia Embedding-u

Vstupom je index j
= token id

Počet neurónov
= počet tokenov

Embedingy sú váhy
 $e_j = w_{1j}, w_{2j}, \dots$



e_j
Váhy jedného z
neurónov

Text

Implementácia Embedding-u

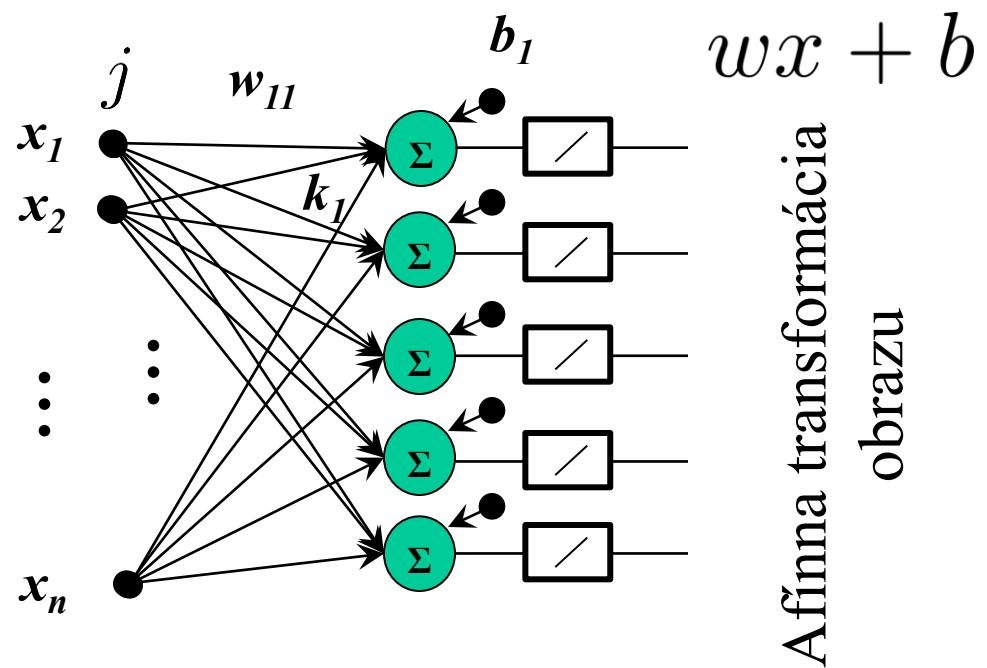
Vstupom sú farby pixelov

$x = \text{flatten}(\text{Patch})$

Patch $C \times H \times W$

$3 \times 8 \times 8 \dots 3 \times 32 \times 32$

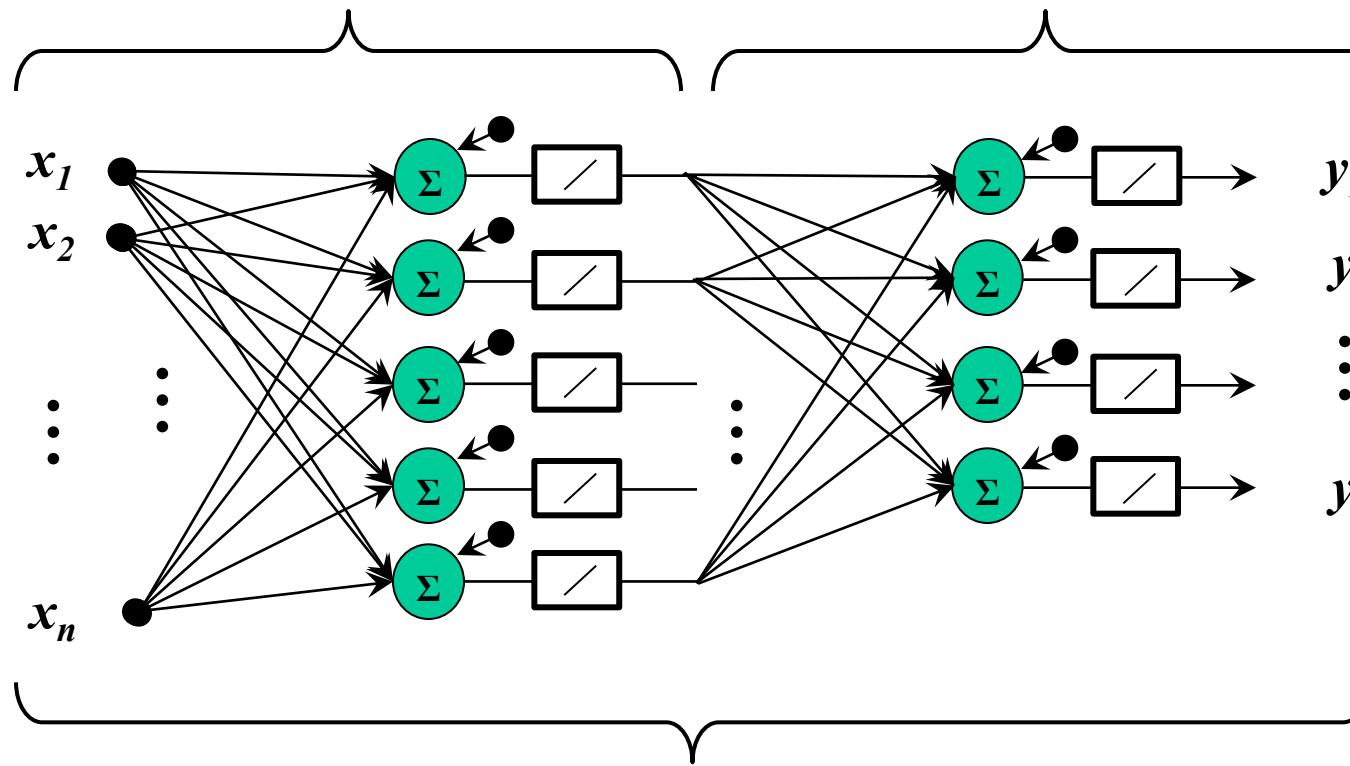
Počet neurónov je
dimensiou priestoru
embeddingov
 $384 \dots 12288$



Obraz

Embedding

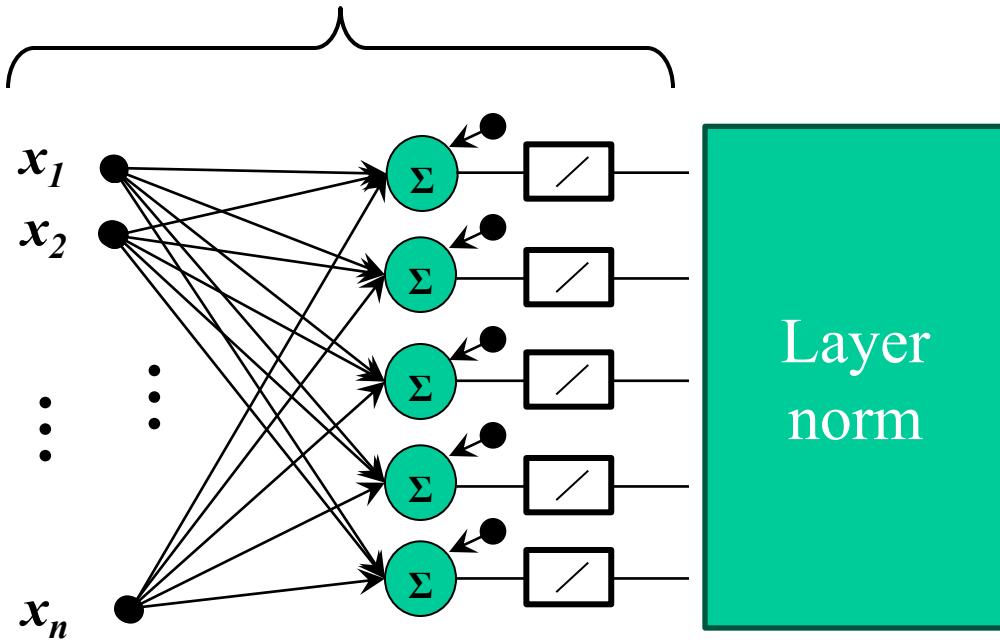
Wipeout



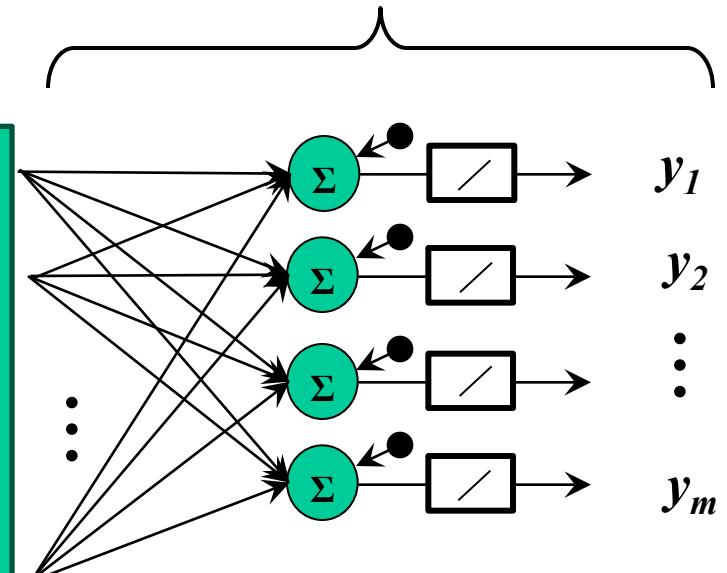
Perceptron

Obraz

Embedding



Wipeout



Obraz

Layer Normalization

$$\text{LayerNorm}(x) = \gamma \frac{x - \mu}{\sqrt{\frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2 + \epsilon}} + \beta$$

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i$$

Pre jeden vstup je x výstupom z nejakej vrstvy

Z týchto výstupov odčítame priemer

Zrátame smerodajnú odchýlku a vydelíme ňou všetky príznaky

Pritom sa pre každý príznak zvlášť učíme škálu γ a biás β

(počet trénovateľných parametrov je $2 \times$ dimenzia)

LN zabezpečuje, že príznaky budú mať zhromaždenú rovnakú veľkosť

RMS Norm

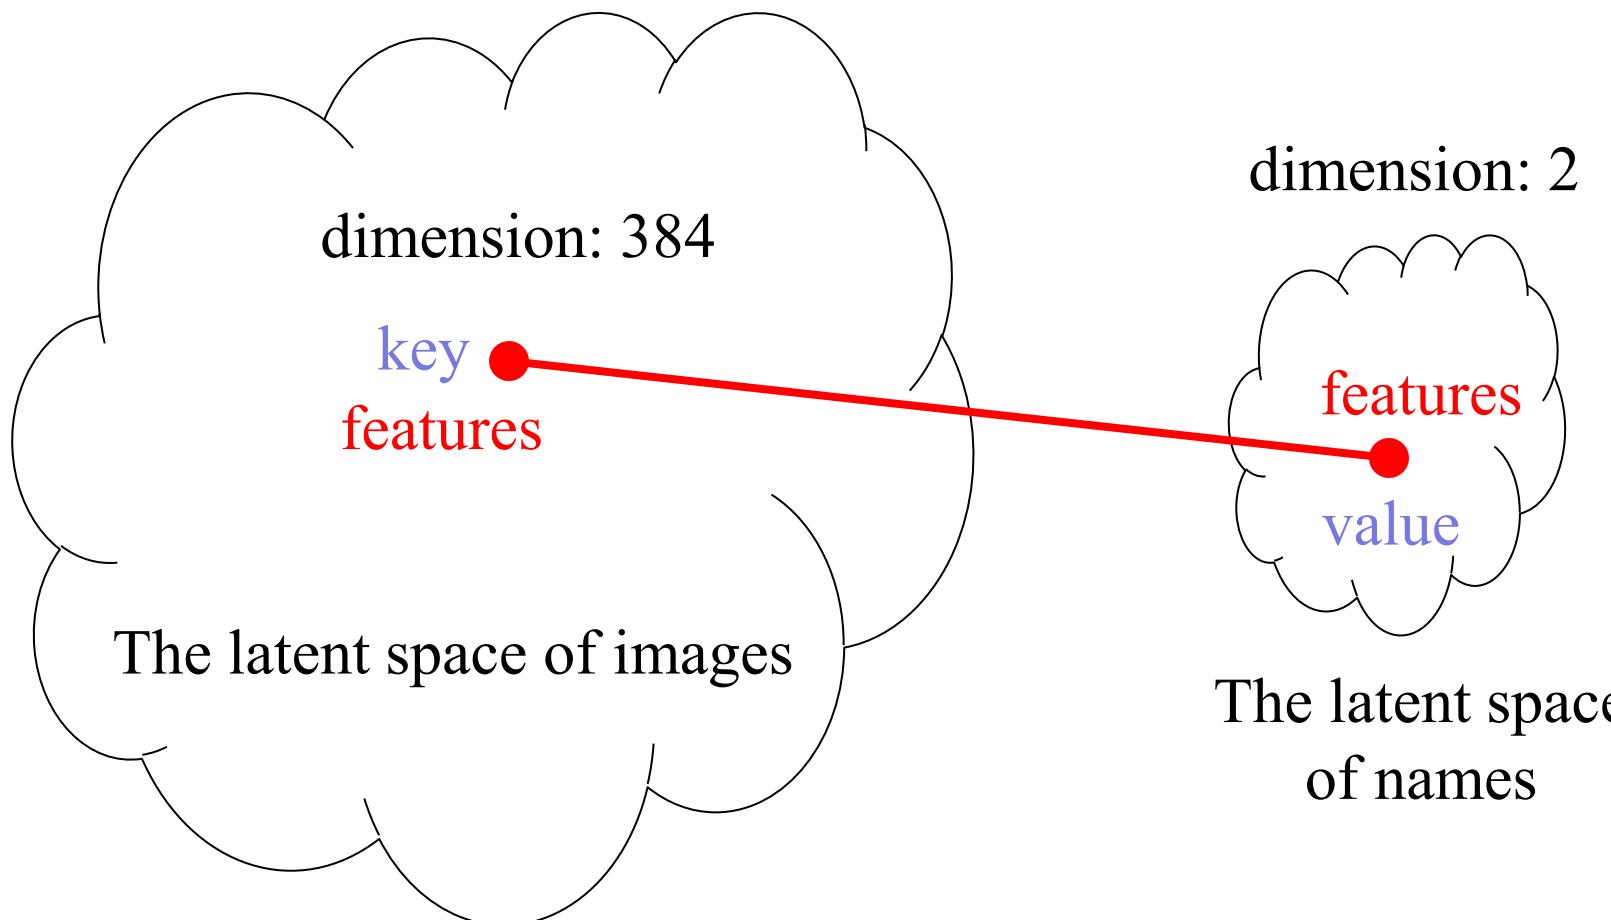
Root Mean Square Normalization

$$\text{RMSNorm}(x) = \gamma \frac{x}{\sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}}$$

Pre jeden vstup je x výstupom znejakej vrstvy
Zrátame smerodajnú odchýlku a vydelíme ňou všetky príznaky
Pritom sa pre každý príznak zvlášť učíme škálu β
(počet trénovateľných parametrov je rovný dimenzii)
RMS Norm zabezpečuje, že príznaky budú mať zhruba rovnakú
veľkosť a budú vycentrované (nemáme biásy)
RMS Norm je rýchlejšia než LN

Associating

unlike the space of images, the latent space of the image features is continuous and fluent



Associating via Attention

1x384

[[0.37	2.63	0.7	0.66	-0.25	-2.94	-1.57	3.66	-1.14	2.21
-2.61	6.49	3.55	-3.92	-1.89	12.06	-4.2	1.16	5.12	-2.41	
3.24	-3.82	0.14	5.06	-2.52	10.69	-1.63	1.73	-0.41	1.6	
0.02	0.11	0.33	-0.84	-2.36	-2.96	-4.43	1.32	-1.57	0.03	
2.32	3.31	1.93	1.46	-0.84	14.62	-0.1	0.49	-3.44	1.89	
-0.53	1.04	-2.	1.58	-3.18	0.46	-5.31	1.68	2.17	-4.7	
0.82	-1.25	-0.17	-5.52	1.06	5.82	-2.36	-1.86	-2.2	-1.93	
-5.48	-2.73	-2.02	-0.53	14.55	-4.19	5.7	-2.02	1.1	-10.93	
-0.3	-1.8	0.97	0.63	-4.91	-1.63	-0.21	-5.03	-3.25	7.83	
-4.9	-1.59	-1.32	1.73	-7.65	0.78	3.06	-2.85	-0.43	4.66	
5.16	2.61	5.53	0.82	0.05	3.62	-1.28	0.7	1.87	-1.19	
-8.28	2.16	0.5	-1.17	1.74	2.08	-4.38	6.68	5.02	6.27	
-3.14	12.75	-16.36	-1.21	7.25	-1.63	1.71	-5.21	6.9	1.98	
-1.75	2.8	-3.03	1.3	7.8	3.06	-4.18	-4.35	-12.24	-0.08	
-3.5	2.51	-0.19	-3.81	-4.18	7.67	-2.84	1.41	0.87	-3.27	
0.16	-0.09	1.73	-2.23	-9.82	-2.58	-3.4	-4.08	0.56	-2.48	
-5.39	4.59	0.72	3.32	3.29	-3.6	-0.13	4.65	-5.15	-5.24	
-2.32	5.93	0.89	2.02	-3.25	-1.98	-0.64	4.24	8.09	-5.61	
-3.6	-0.18	-5.54	0.6	-3.88	-5.02	2.02	-1.16	1.77	2.58	
-1.25	0.32	-4.24	3.61	-0.5	-2.89	1.52	7.71	-2.9	10.41	
-3.12	-5.3	4.03	2.	-5.6	-2.29	7.02	3.53	2.36	-2.59	
1.41	5.	2.18	-2.36	3.39	5.55	4.47	1.59	4.22	0.68	
1.92	-0.12	-3.52	-2.86	1.18	-1.92	9.13	-1.04	0.71	3.39	
-5.35	-1.52	-3.46	4.2	-0.22	-0.17	5.58	1.04	-5.02	0.95	
-0.57	4.32	-2.39	2.71	-1.65	-1.62	3.19	-1.44	0.61	2.51	
-2.11	2.93	-0.2	-13.94	-3.31	-5.4	6.45	-3.6	4.73	-2.23	
-1.02	0.57	-1.45	0.89	-3.3	-0.41	2.56	-15.4	-3.78	-6.35	
1.45	9.59	-3.38	6.18	-6.55	4.05	-2.75	3.43	-6.72	-7.45	
6.67	-7.03	-1.58	6.16	-0.84	-0.22	2.63	-2.92	-6.13	-4.14	
1.31	-2.06	1.31	0.02	1.42	1.36	-2.95	7.2	-10.27	1.29	
1.42	1.56	5.59	4.71	-3.84	-0.	2.94	-4.96	-1.7	-0.57	
6.49	4.24	3.33	4.18	0.52	2.82	-3.45	-6.27	1.52	-3.25	
-3.31	4.92	4.1	2.47	-0.99	9.92	2.36	-7.38	3.18	0.93	
-0.37	3.08	-2.4	-0.33	-2.97	5.68	1.38	-10.75	1.02	4.69	
4.61	-4.56	4.14	-4.58	0.44	-6.04	-6.2	-3.05	-3.61	-1.19	
-0.05	1.59	1.01	1.36	-1.4	4.09	4.56	6.13	-1.64	-0.25	
-1.57	-2.04	0.74	-6.78	-3.18	0.09	-0.53	6.95	5.38	4.57	
1.83	-2.76	0.59	-3.79	4.85	-4.15	1.11	-3.35	0.87	-4.42	
-1.34	4.35	7.02	-1.62]]					

key

Somehow, we must use the collected key-value pairs to calculate a proper response when we get an unassociated query.

1x2



array([[0.64, -0.32]])

value

We roughly mix the query from the available keys and create the output as an analog mixture of the corresponding values.

Attention

Máme l klúčov dimenzie
 n a l hodnôt dimenzie m

$$K = \begin{pmatrix} k_1 \\ k_2 \\ \dots \\ k_l \end{pmatrix} \quad V = \begin{pmatrix} v_1 \\ v_2 \\ \dots \\ v_l \end{pmatrix}$$

Pre vstupný dotaz q , snažíme sa namiešať z klúčov K jeho nejakú projekciu do pod priestoru klúčov:

$$\text{proj}_K(q) = cK \quad \text{kde} \quad c = \text{softmax}\left(\frac{qK^T}{d}\right)$$

Výstupom bude analogická miešanina zodpovedajúcich hodnôt V

$$A(q, K, V) = \text{softmax}\left(\frac{qK^T}{d}\right)V$$

Pre vhodný škál'ovací faktor d

(pri menšom d , namiešavame viac z klúčov podobných dotazu)

Attention

Máme l klúčov dimenzie
 n a l hodnôt dimenzie m

$$K = \begin{pmatrix} k_1 \\ k_2 \\ \dots \\ k_l \end{pmatrix} \quad V = \begin{pmatrix} v_1 \\ v_2 \\ \dots \\ v_l \end{pmatrix}$$

Pre vstupný dotaz q , snažíme sa namiešať z klúčov K jeho nejakú projekciu do pod priestoru klúčov:

softmax čokol'vek premení na vektor pravdepodobnosti

$$proj_K(q) = cK \quad \text{kde} \quad c = softmax\left(\frac{qK^T}{d}\right)$$

softmax vráti koeficienty miešaniny klúčov

Výstupom bude analogická miešanina zodpovedajúcich hodnôt V

$$A(q, K, V) = softmax\left(\frac{qK^T}{d}\right)V$$

Pre vhodný škál'ovací faktor d = odmocnina z dimenzie klúčov
(pri menšom d , namiešavame viac z klúčov podobných dotazu)

Attention

Pokial' je kl'účov menej ako je dimenzia priestoru, generujú v ňom podpriestor. Ked' dotaz(query) q neleží v tomto podpriestore, attention dáva preň rovnakú odozvu ako pre jeho kolmý priemet do tohto podpriestoru.

$$A(q, K, V) = A(\text{proj}_K^{\text{ort}}(q), K, V)$$

Vyplýva to z toho, že skalárny súčin vektora s vektorom generujúcim určitý podpriestor je rovnaký ako skalárny súčin jeho priemetu do tohto podpriestoru

$$\begin{aligned} \text{proj}_K^{\text{ort}}(q)k_i &= qk_i \\ \text{pre } k_i &\in K \end{aligned}$$

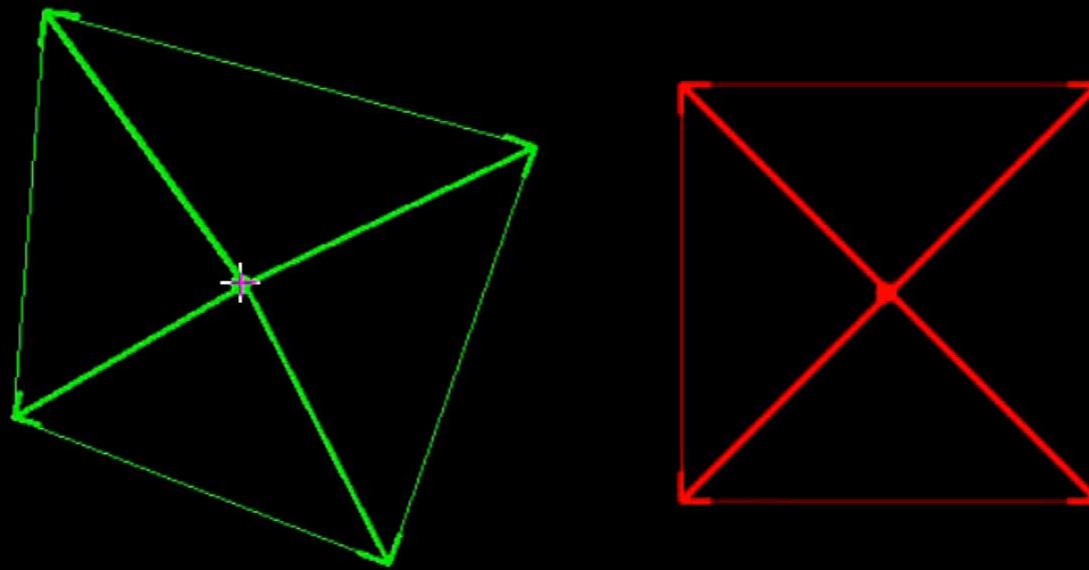
Týmto spôsobom attention generalizuje. Abstrahuje od určitých príznakov, napríklad od tých ktoré majú všetky kl'úče rovnaké

Scaling factor

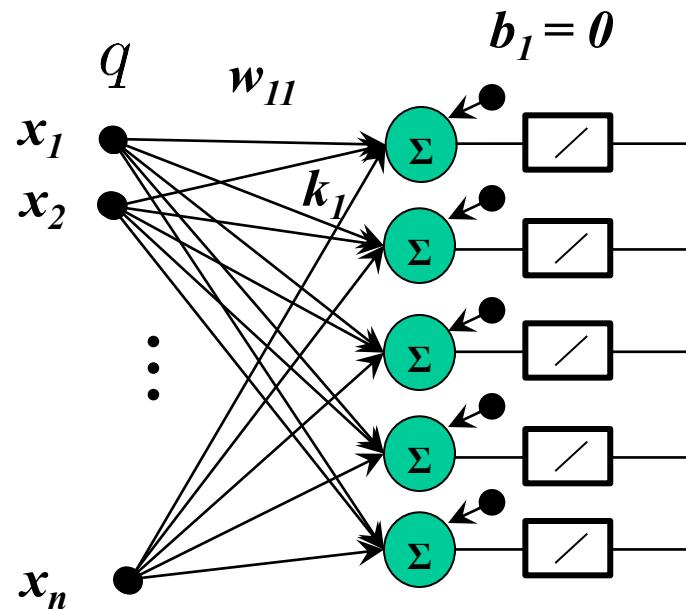
$1/n^2$

\sqrt{n}

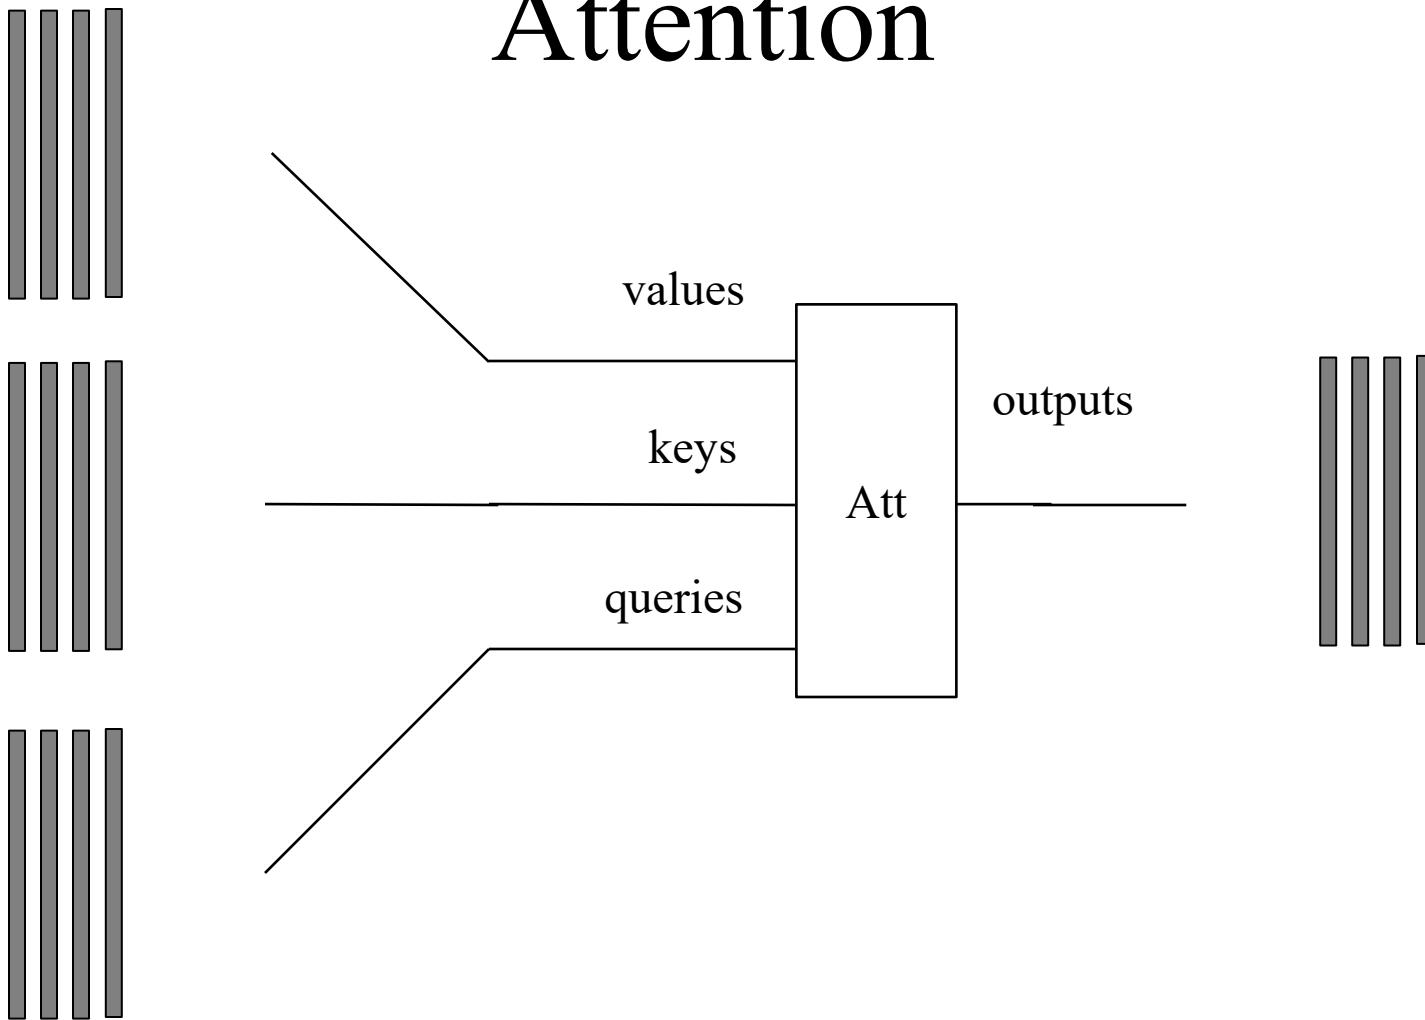
scalin...or: 10



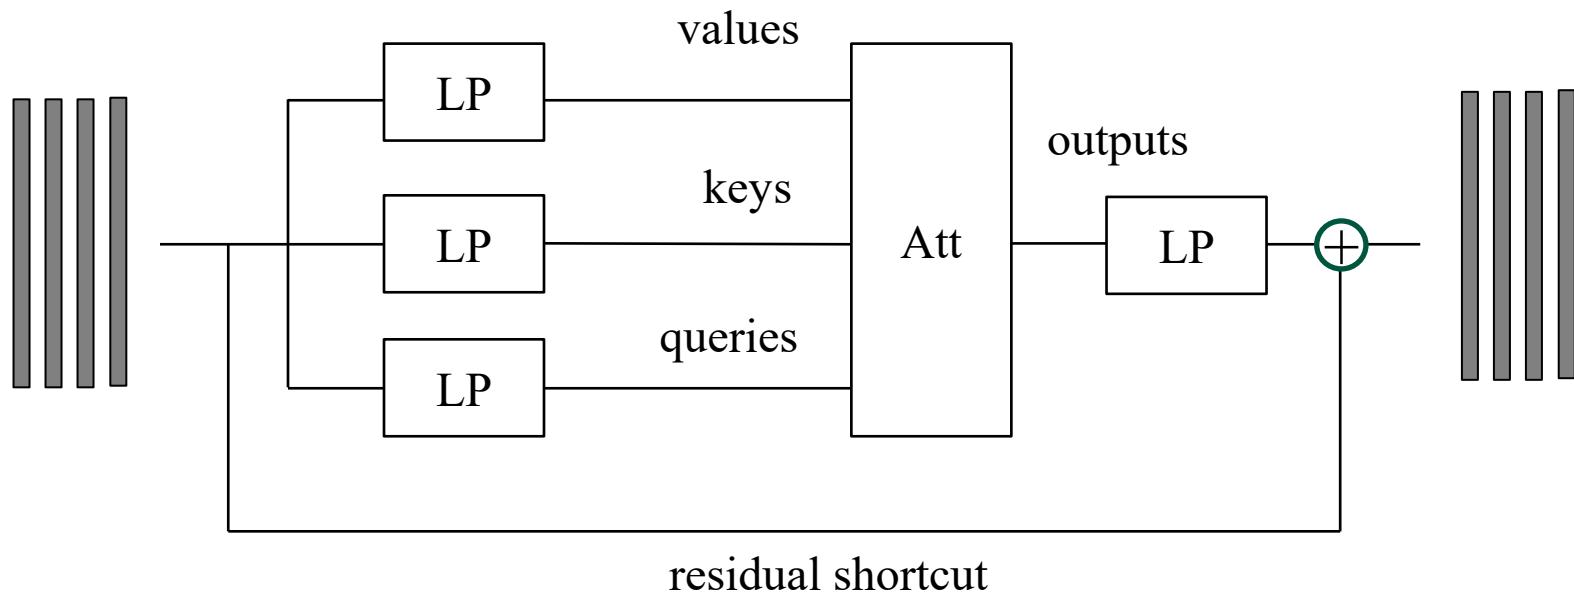
Linear projection



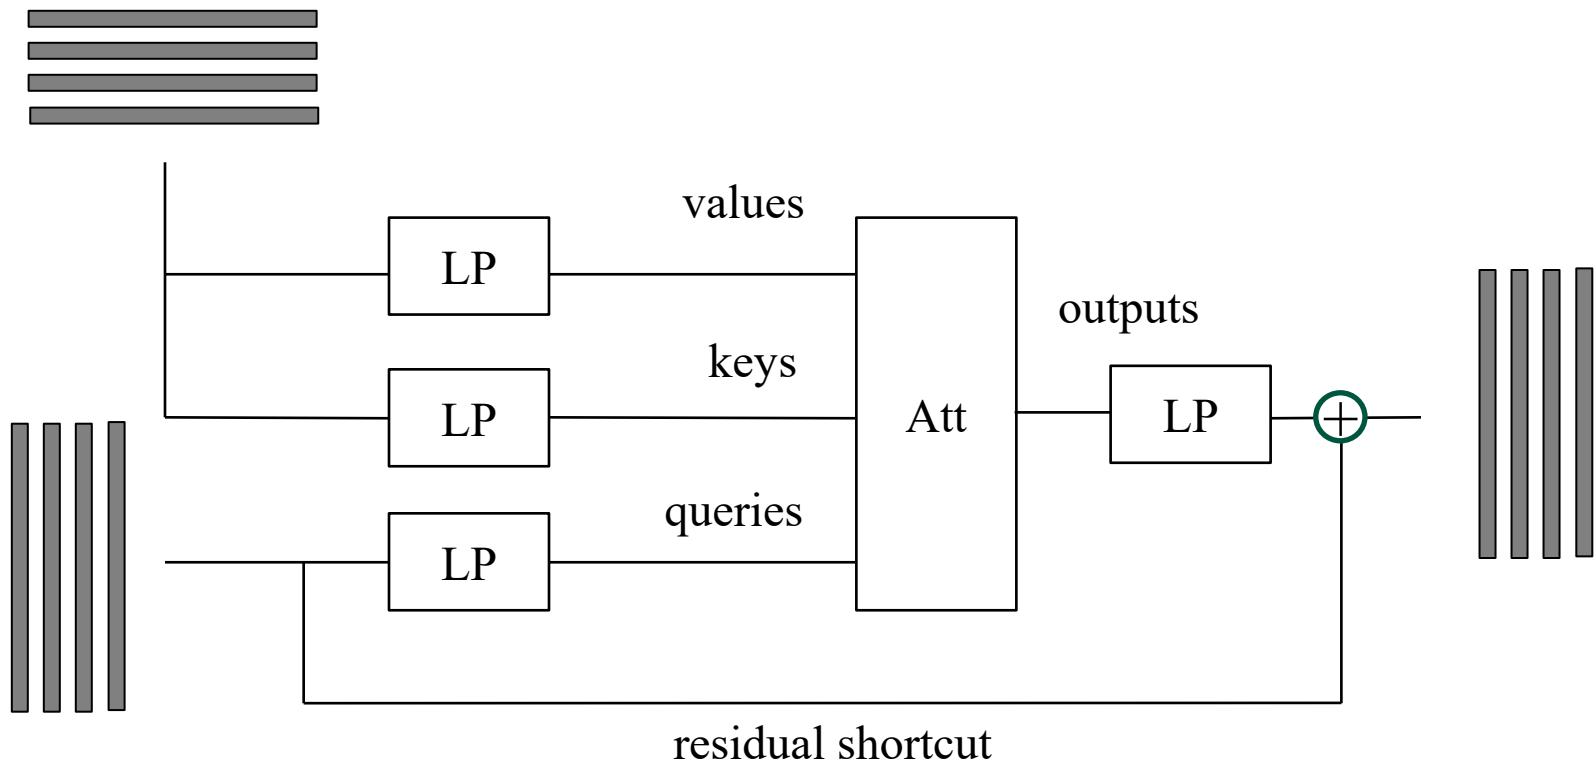
Attention



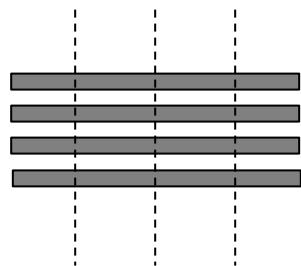
Residual Self-attention



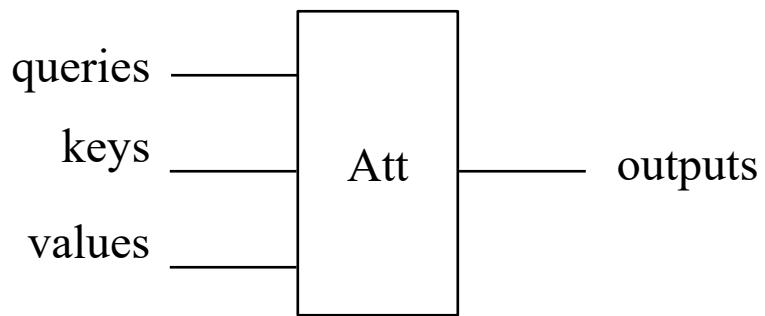
Residual Cross-attention



Multihead attention



Teplo ta



$$Att(Q, K, V) = \text{softmax} \left(\frac{QK^T}{t\sqrt{d}} \right) V$$

teplota dimenzia

Two grey arrows point from the words "teplota" and "dimenzia" towards the terms $t\sqrt{d}$ in the softmax formula.